UNIVERSIDAD EIA · Ingeniería de Datos
Arquitecturas de Datos 2026-2

Data Lake de noticias RSS en AWS

Evidencias de funcionamiento

Estudiante: Dylan Mejia y Juan Pablo Monsalve
Profesor: Santiago Méndez

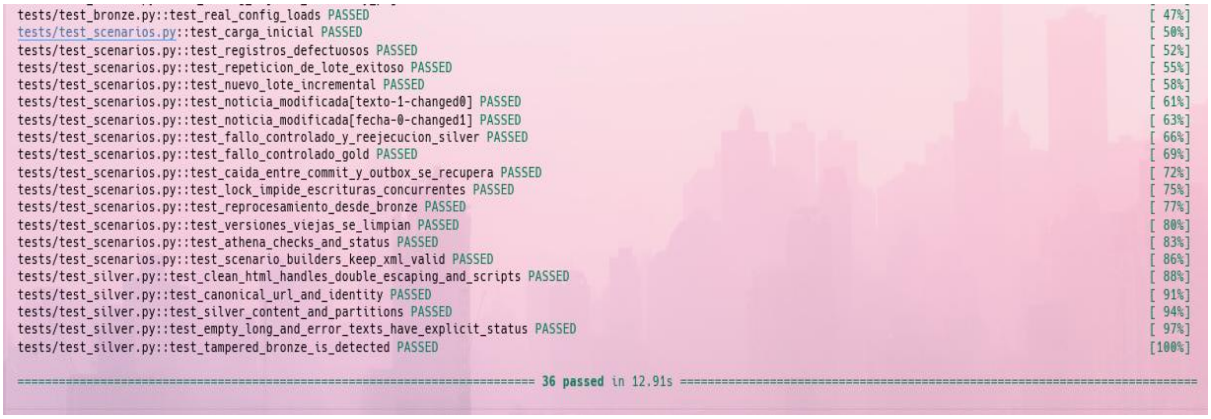
Correspondencia con los entregables (sección 5.3)

Evidencia pedida	Capturas
Ejecución del DAG en Airflow	E07–E11, E47, E51, E53, E55
Archivos de Bronze, Silver y Gold	E03, E12–E14
Resultados de Comprehend	E25, E26, E42, E44
Tablas y particiones en Glue Data Catalog	E04, E05, E15, E58–E60
Consultas y resultados en Athena	E06, E16–E31
Validación de escenarios de calidad, incrementalidad y recuperación	E01, E32–E61

1. Pruebas locales

Las pruebas automatizadas recorren los escenarios.

E01 · Pruebas automatizadas (pytest)



2. Despliegue de la infraestructura

Infraestructura creada con Terraform: bucket único con todas las zonas, Glue Data Catalog, Athena y Airflow en EC2.

E02 · Despliegue con Terraform

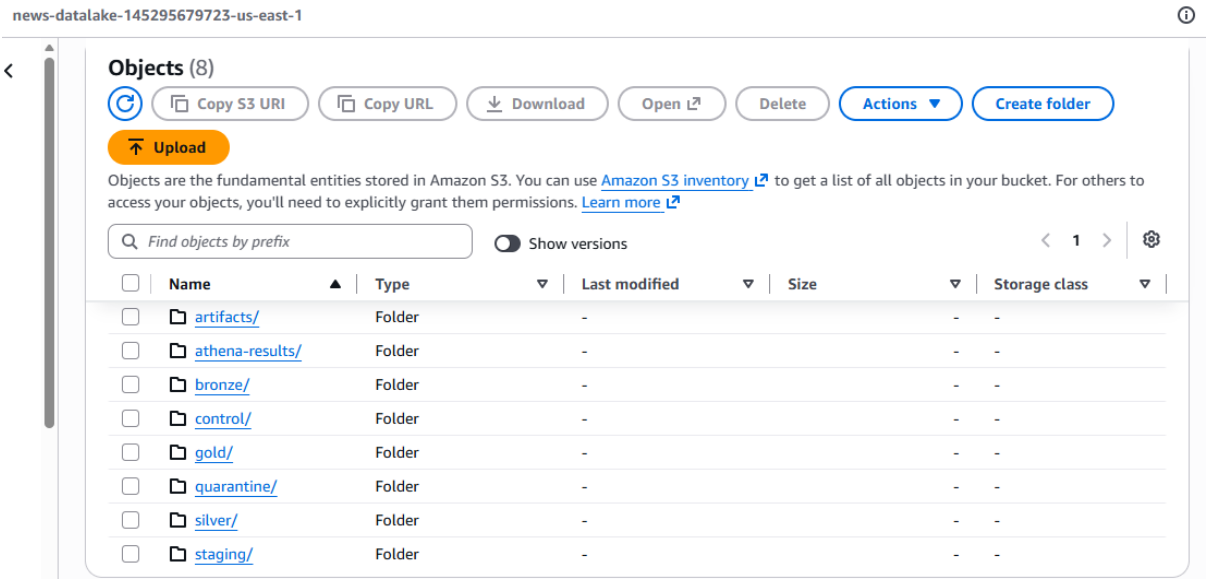
```
aws_instance.airflow: Creating...
aws_instance.airflow: Still creating... [00m10s elapsed]
aws_instance.airflow: Creation complete after 13s [id=i-06da8bc5a7b71a4e5]

Apply complete! Resources: 75 added, 0 changed, 0 destroyed.

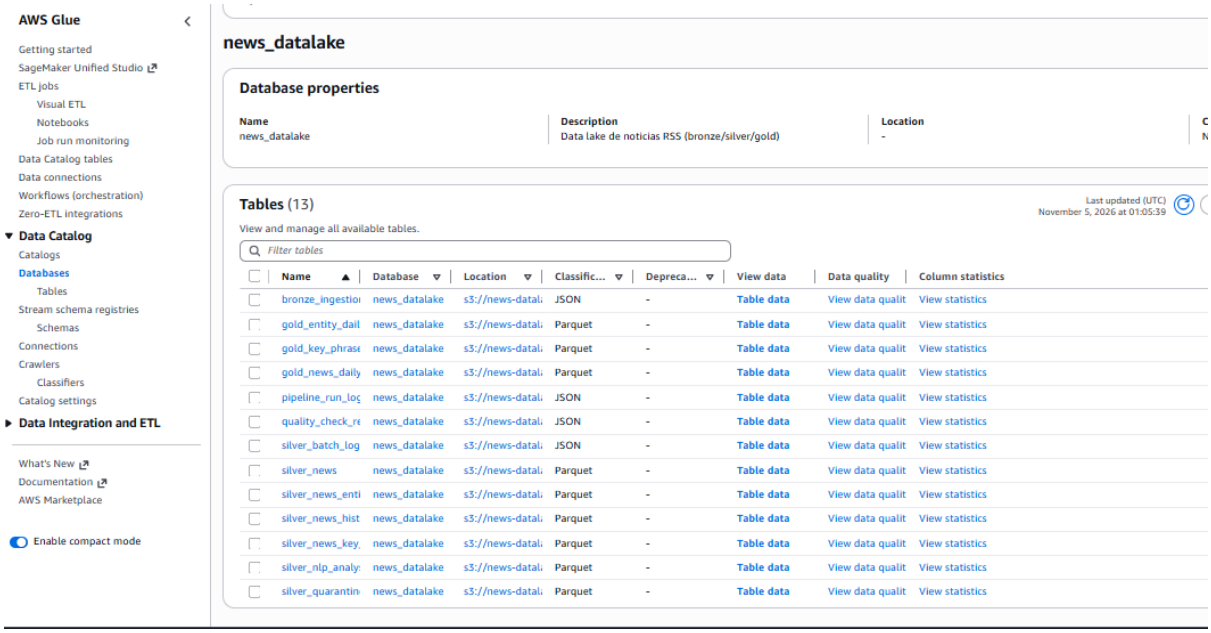
Outputs:

airflow_admin_password_cmd = "aws ssm get-parameter --name /news-datalake/airflow/admin_password --with-decryption --query Parameter.Value --output text"
airflow_ui_tunnel_cmd = "aws ssm start-session --target i-06da8bc5a7b71a4e5 --document-name AWS-StartPortForwardingSession --parameters portNumber=8080,localPortNumber=808
0"
athena_workgroup = "news-datalake"
bucket_name = "news-datalake-145295679723-us-east-1"
ec2_shell_cmd = "aws ssm start-session --target i-06da8bc5a7b71a4e5"
glue_database = "news_datalake"
instance_id = "i-06da8bc5a7b71a4e5"
```

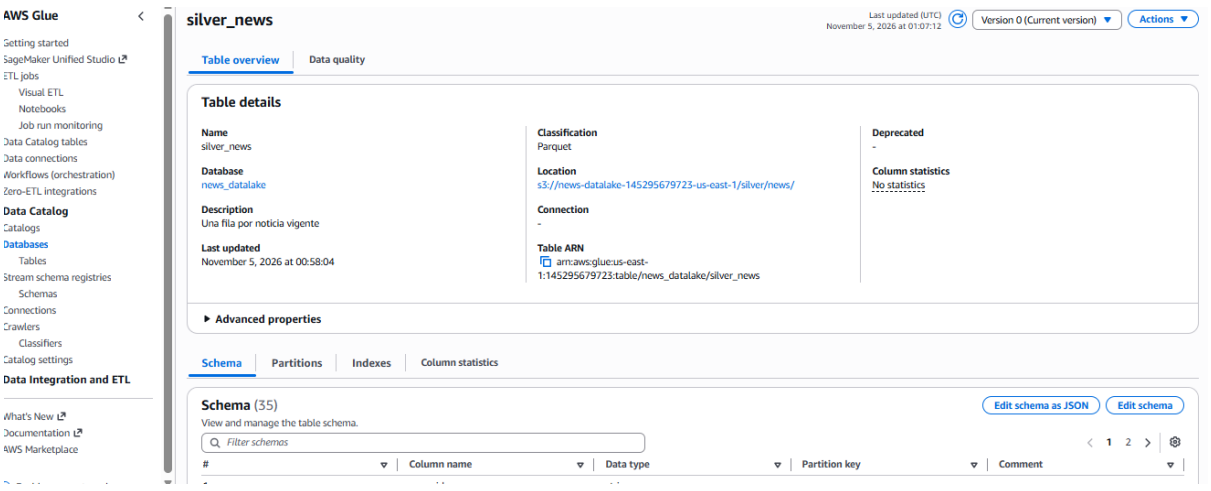
E03 · Zonas del data lake en un solo bucket S3

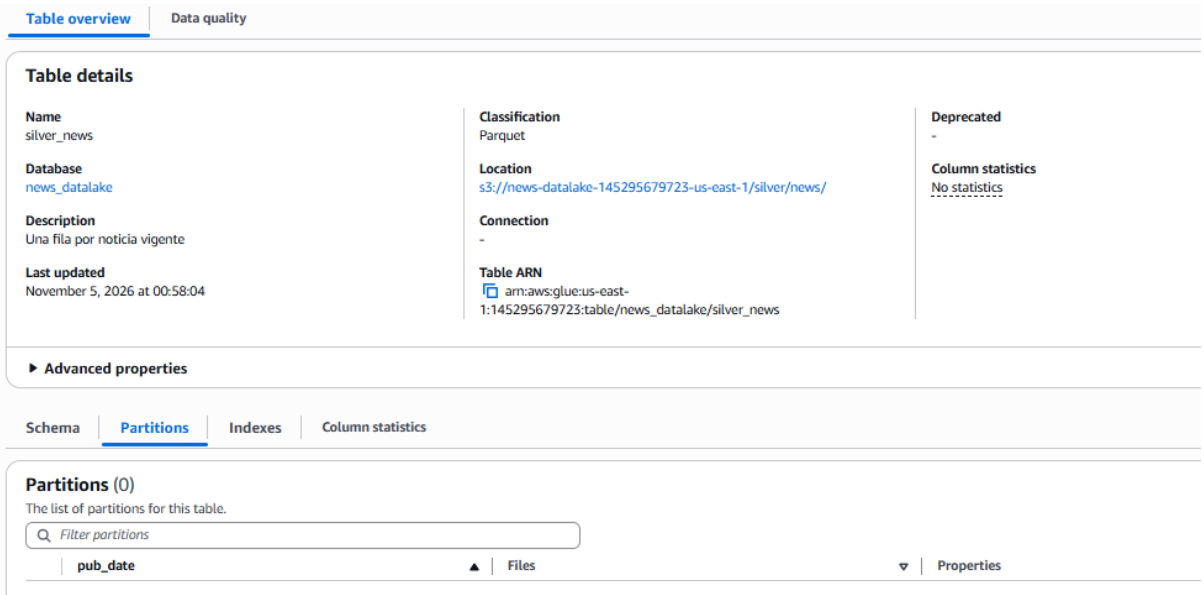


E04 · Tablas registradas en AWS Glue Data Catalog

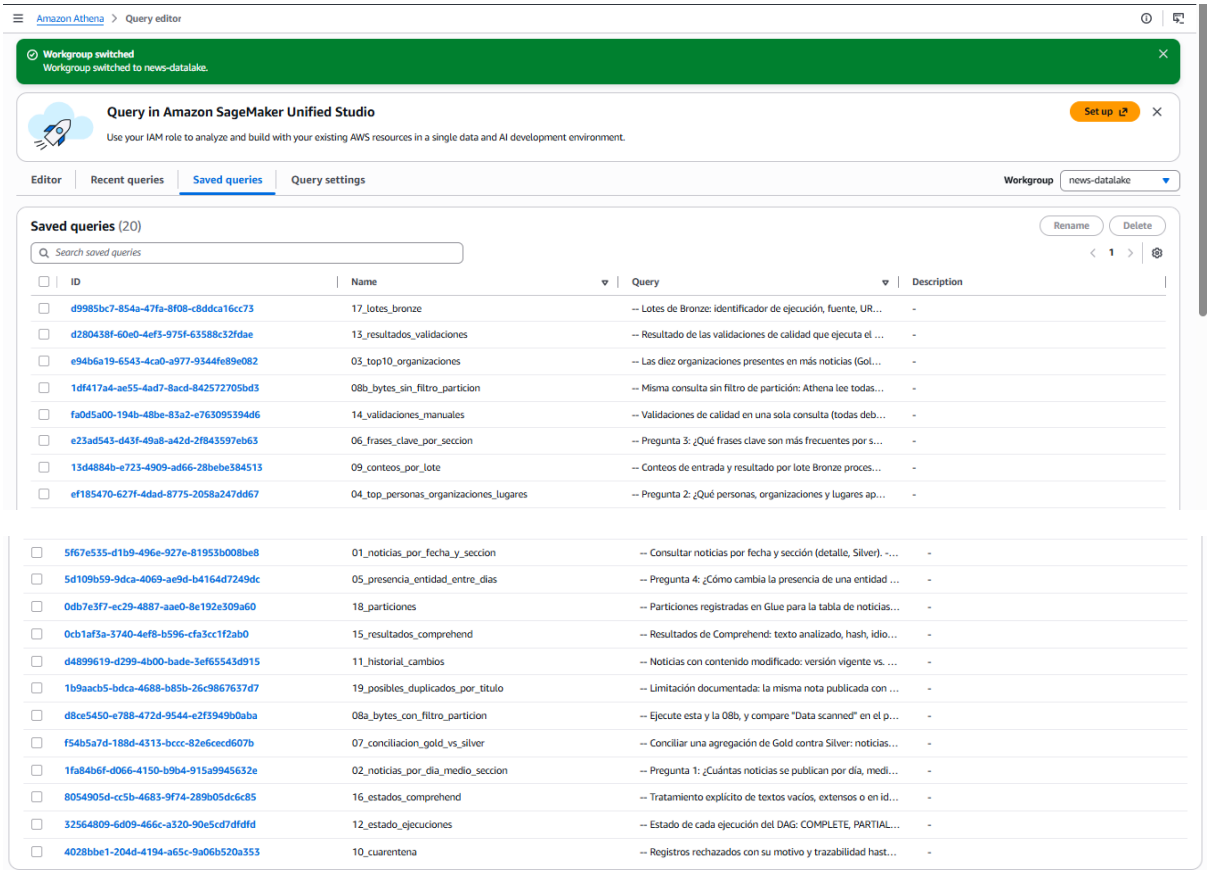


E05 · Esquema de silver_news en Glue

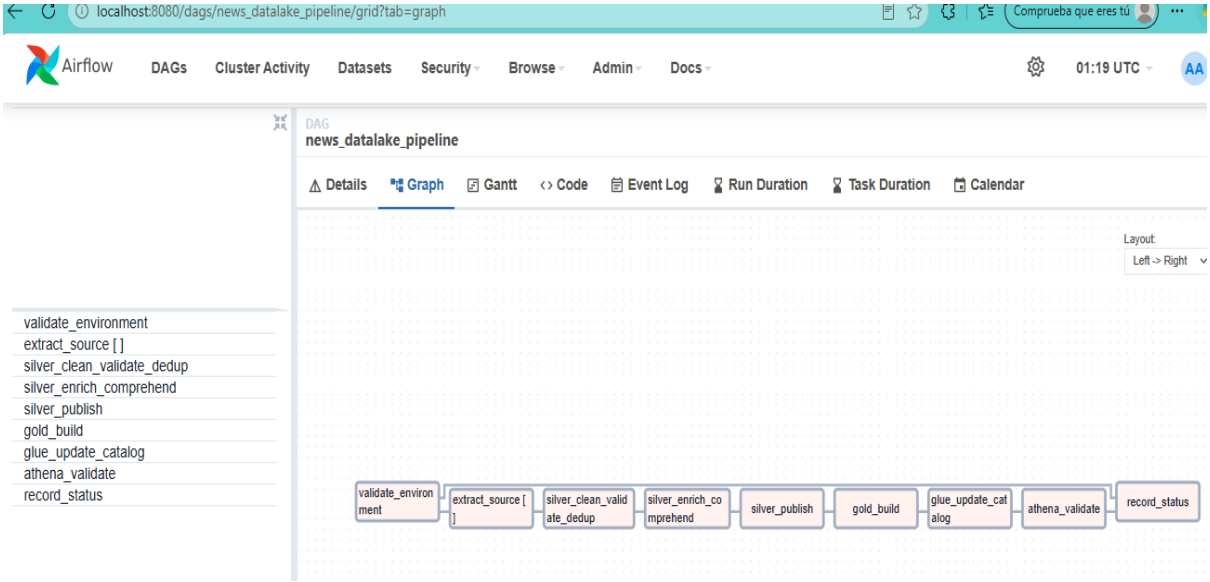




E06 · Consultas guardadas en Athena



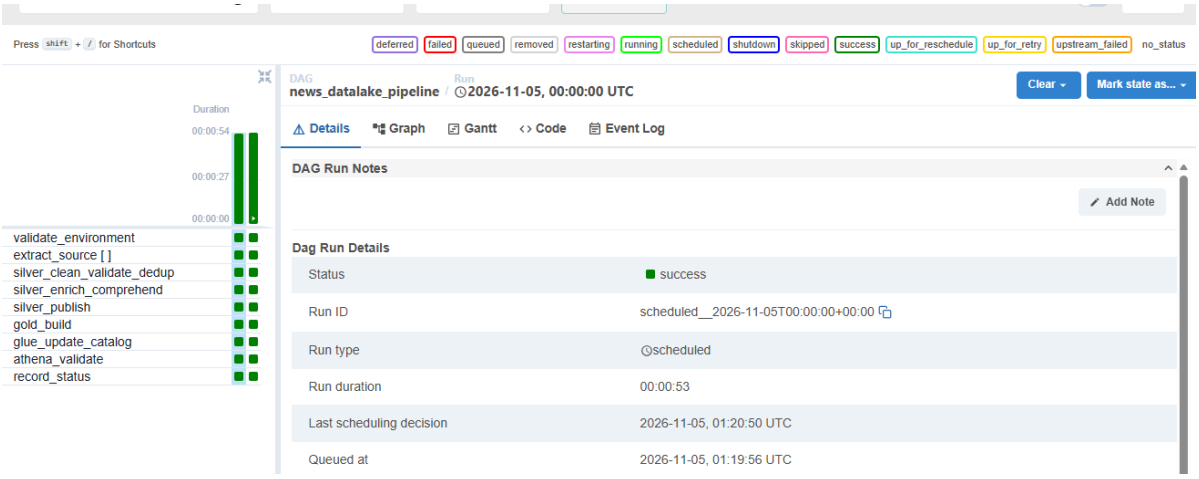
E07 · Grafo del DAG con los 9 pasos



3. Carga inicial

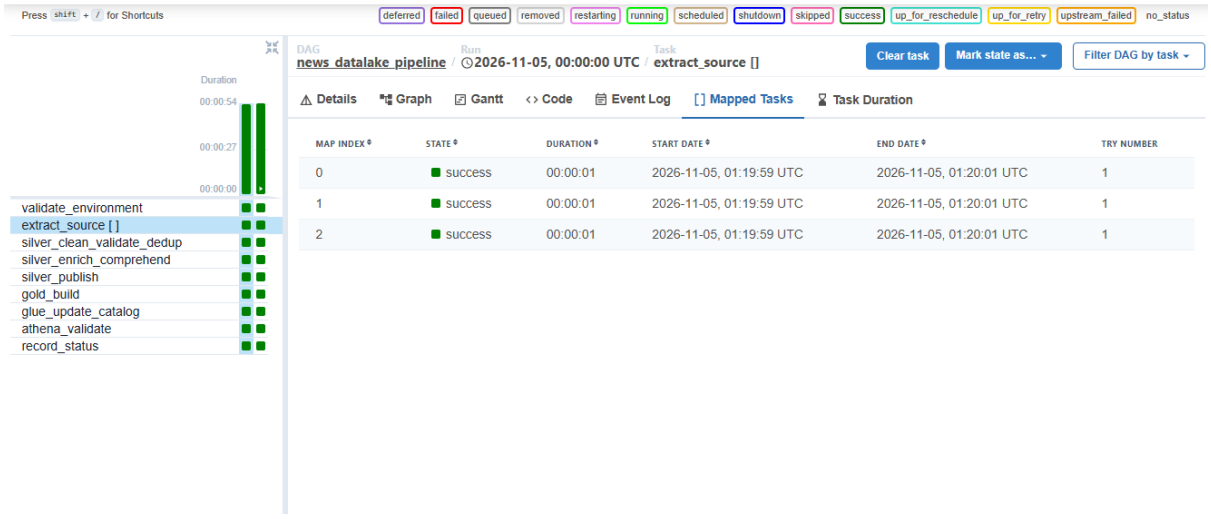
Primera ejecución del DAG: datos en Bronze, Silver y Gold, y particiones registradas en Glue.

E08 · Ejecución exitosa del DAG



E09 · Log de extracción: fuente, lote, HTTP y hash

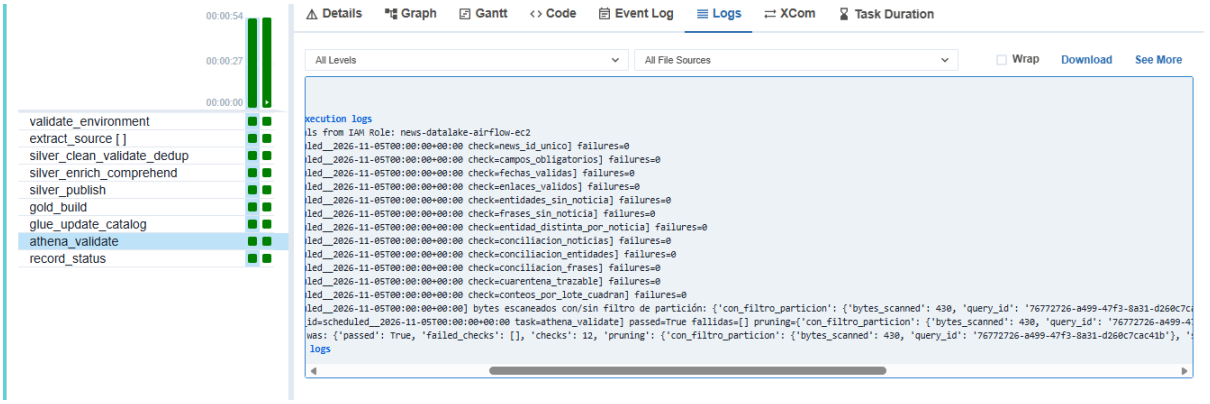


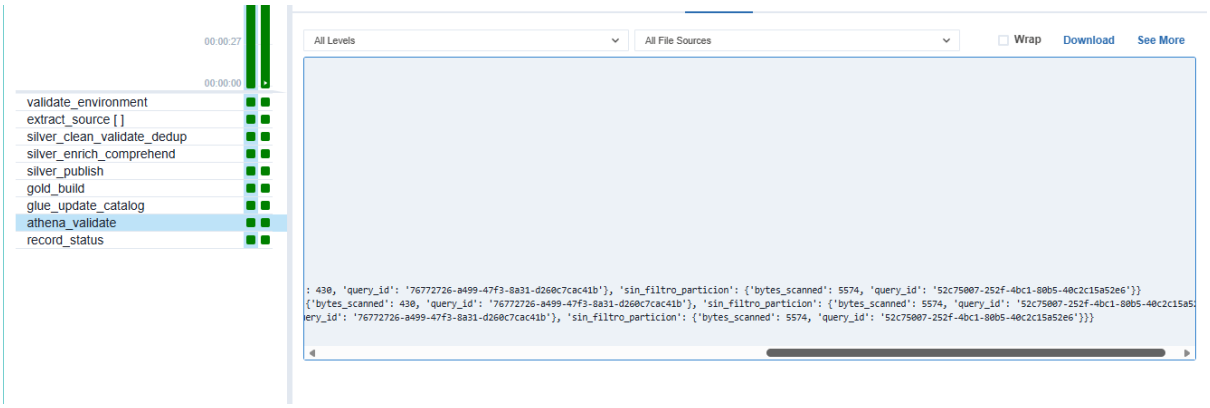


E10 · Log de publicación de Silver

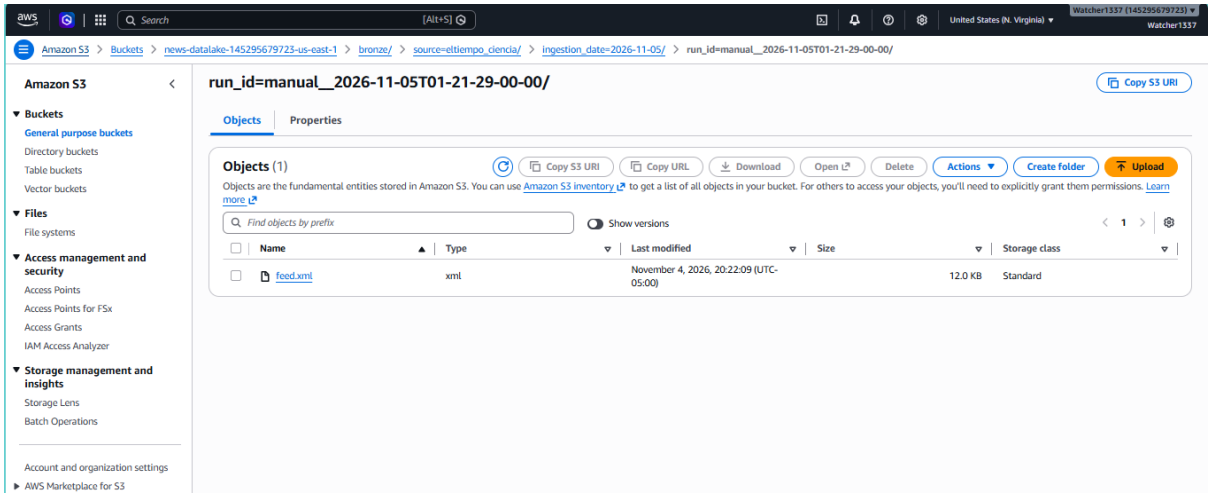


E11 · Log de validaciones con Athena

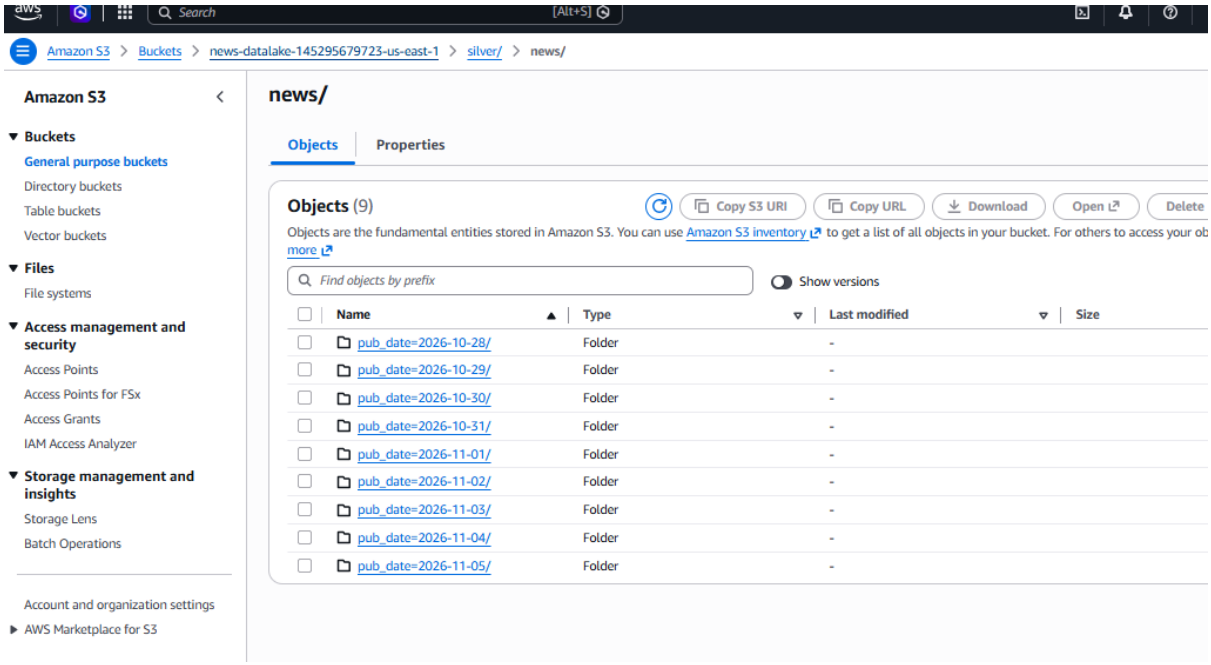


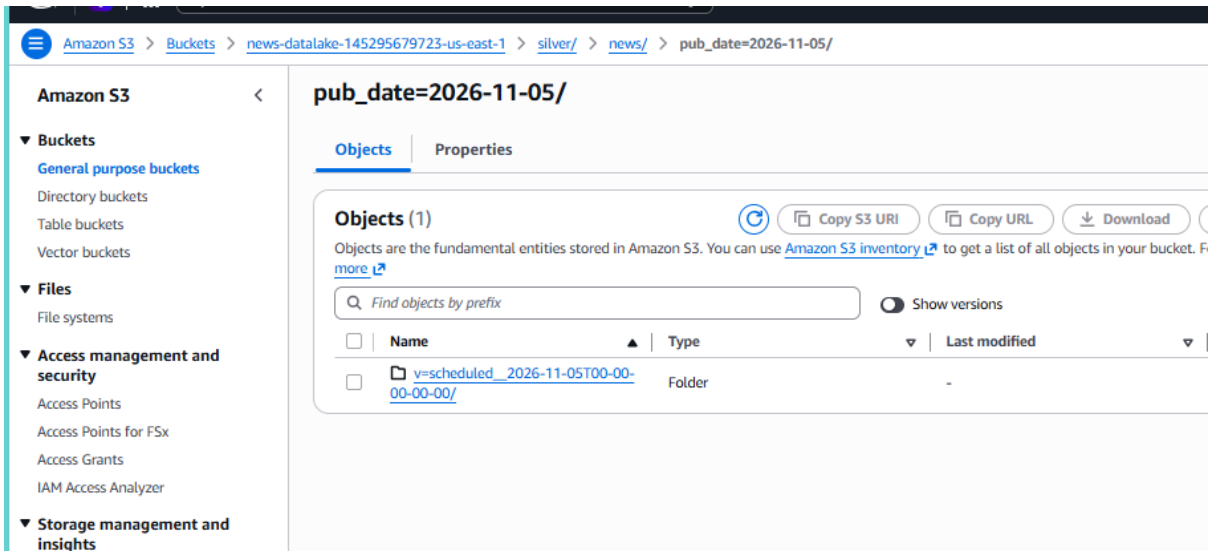


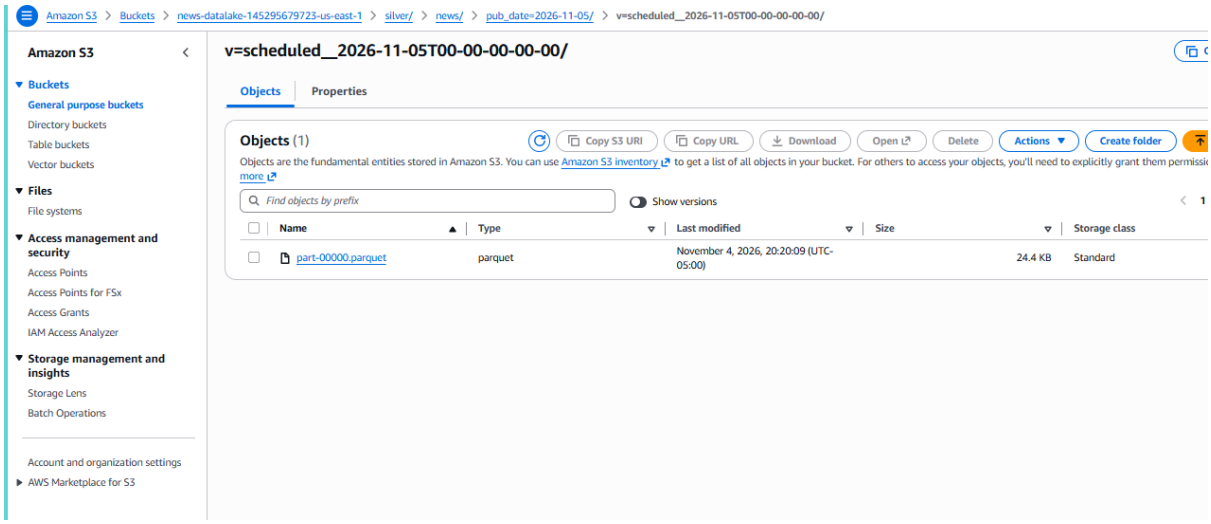
E12 · Archivo original en Bronze



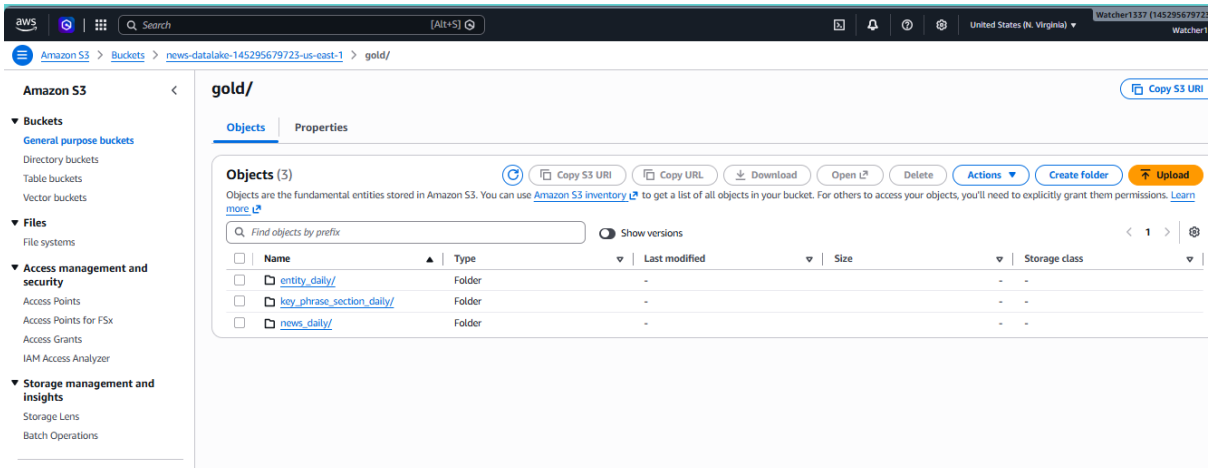
E13 · Particiones de Silver en S3

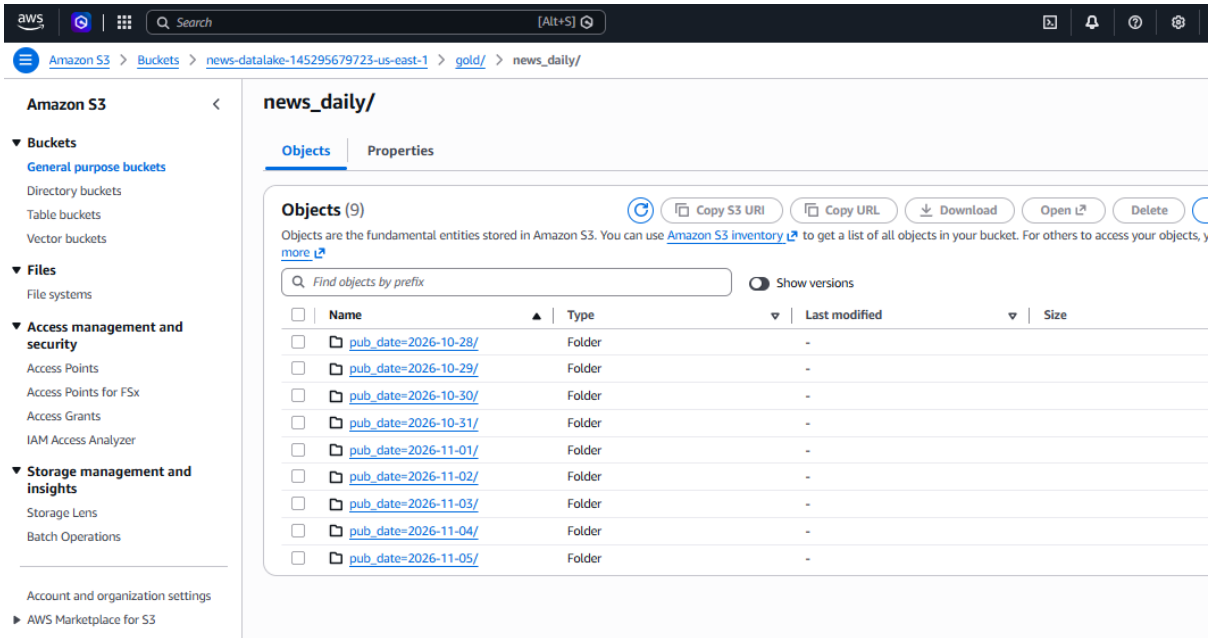




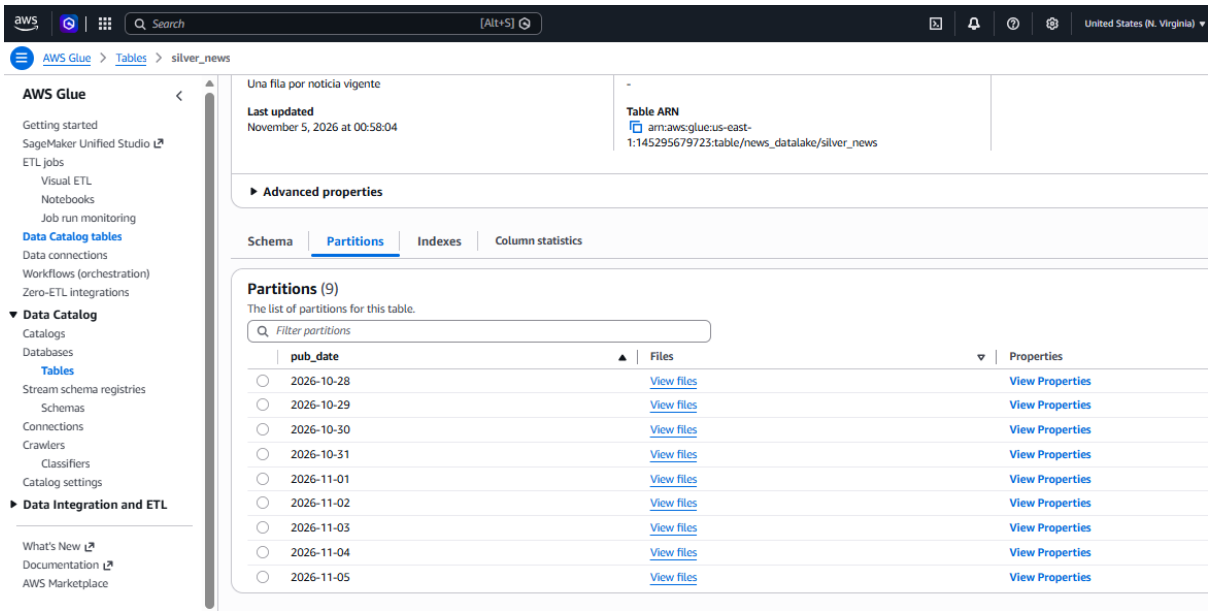


E14 · Tablas de Gold en S3





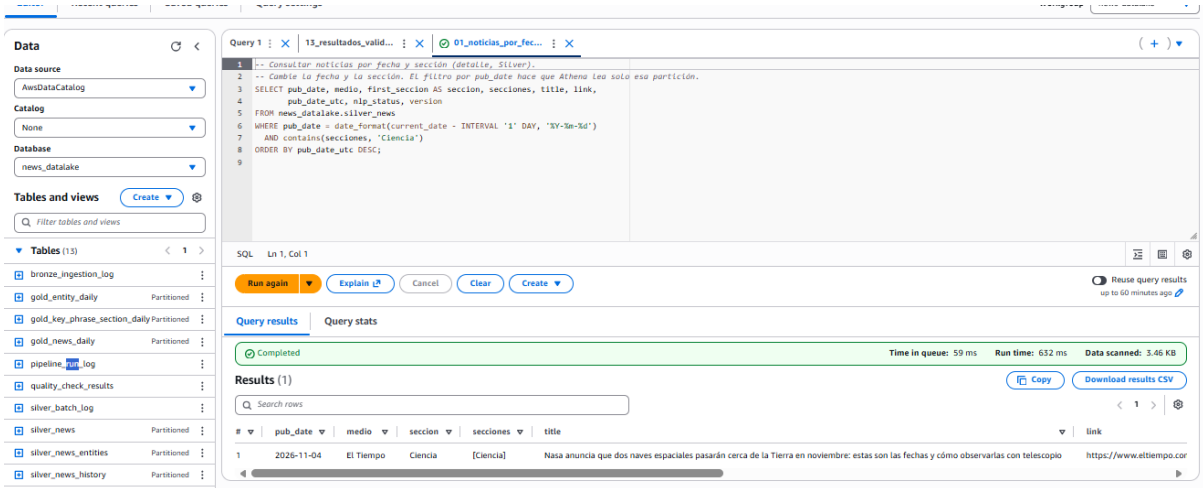
E15 · Particiones de silver_news en Glue


Search
[Alt+S]
United States (N. Virginia)
AWS Glue
Tables
silver_news
AWS Glue
Getting started
SageMaker Unified Studio
ETL jobs
Visual ETL
Notebooks
Job run monitoring
Data Catalog tables
Data connections
Workflows (orchestration)
Zero-ETL integrations
Data Catalog
Catalogs
Databases
Tables
Stream schema registries
Schemas
Connections
Crawlers
Classifiers
Catalog settings
Data Integration and ETL
What's New
Documentation
AWS Marketplace
Una fila por noticia vigente
Last updated
November 5, 2026 at 00:58:04
-
Table ARN
arn:aws:glue:us-east-1:145295679723:table/news_datalake/silver_news
Advanced properties
Schema
Partitions
Indexes
Column statistics
Partitions (9)
The list of partitions for this table.
Filter partitions
pub_date
Files
Properties
2026-10-28 View files View Properties
2026-10-29 View files View Properties
2026-10-30 View files View Properties
2026-10-31 View files View Properties
2026-11-01 View files View Properties
2026-11-02 View files View Properties
2026-11-03 View files View Properties
2026-11-04 View files View Properties
2026-11-05 View files View Properties

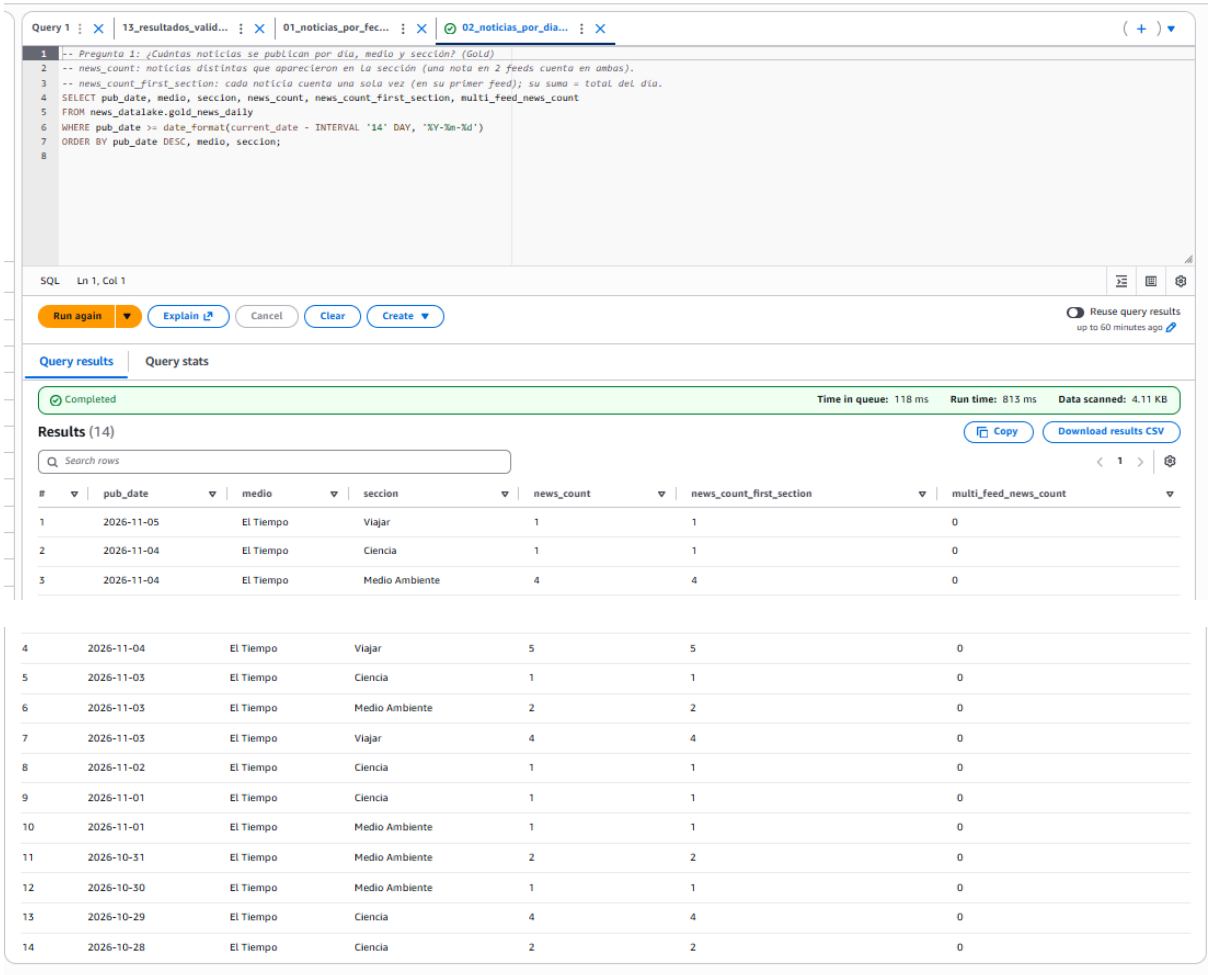
4. Consultas en Athena

Indicadores de Gold, resultados de Comprehend, validaciones de calidad y efecto del particionamiento.

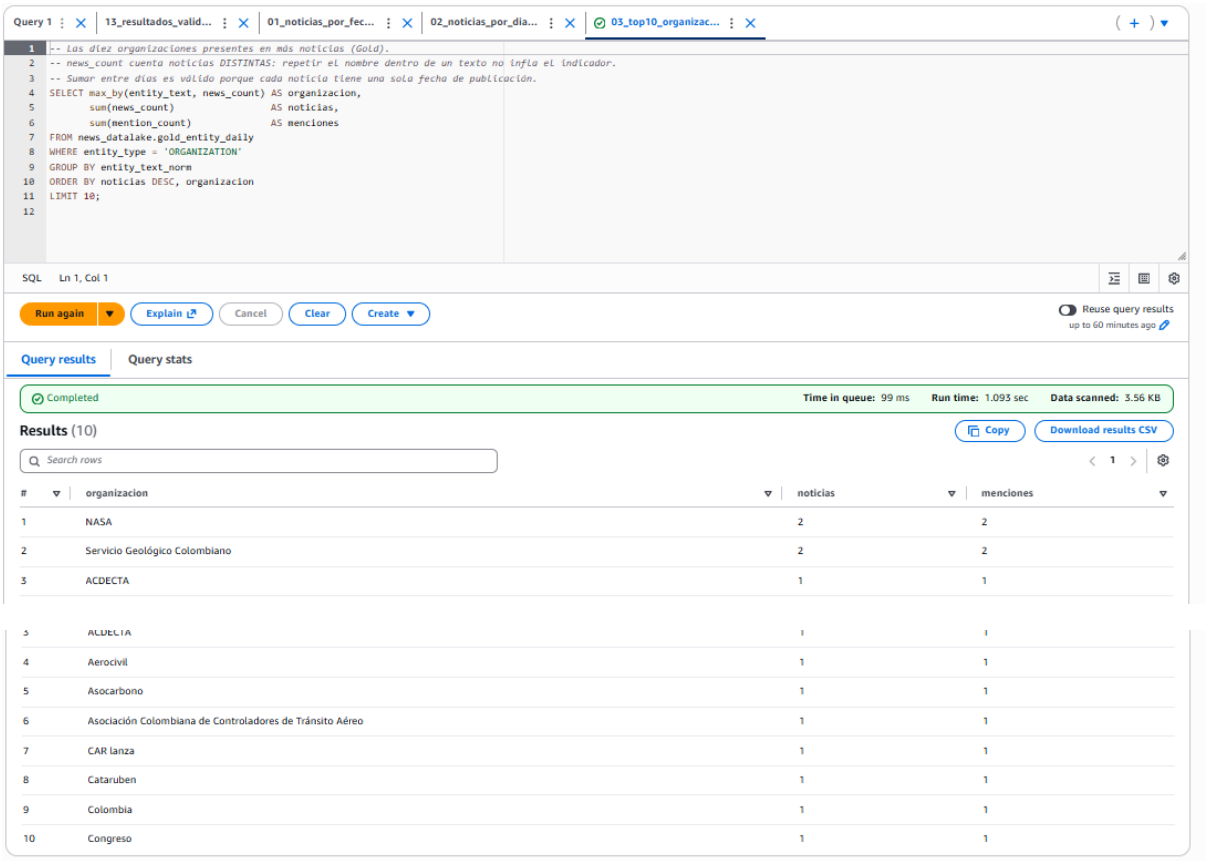
E16 · Noticias por fecha y sección



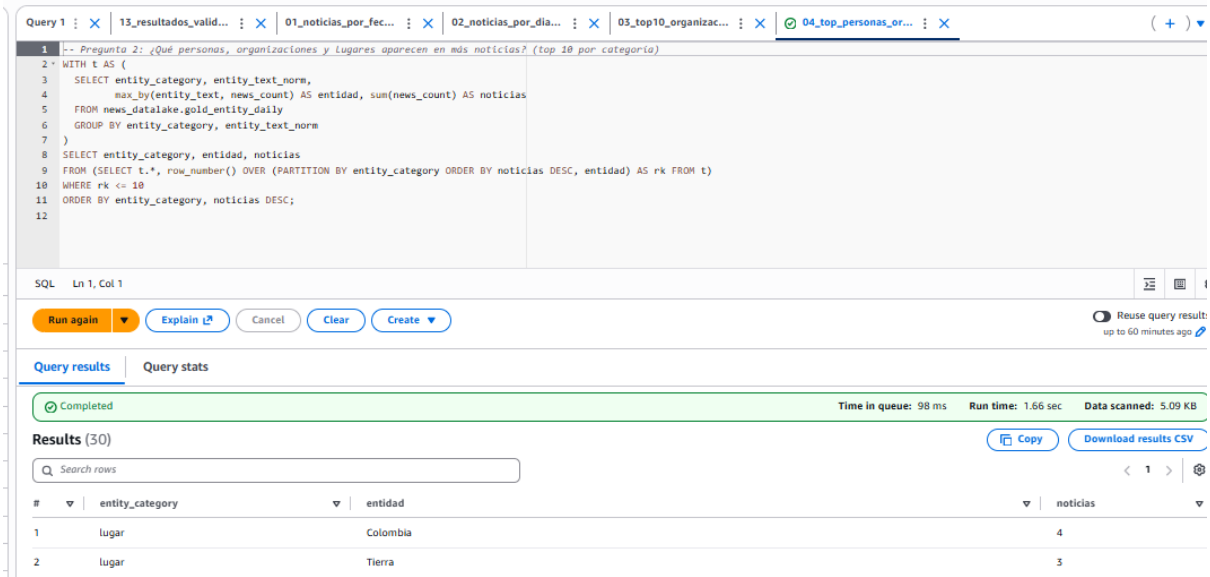
E17 · Pregunta 1: noticias por día, medio y sección



E18 · Diez organizaciones presentes en más noticias



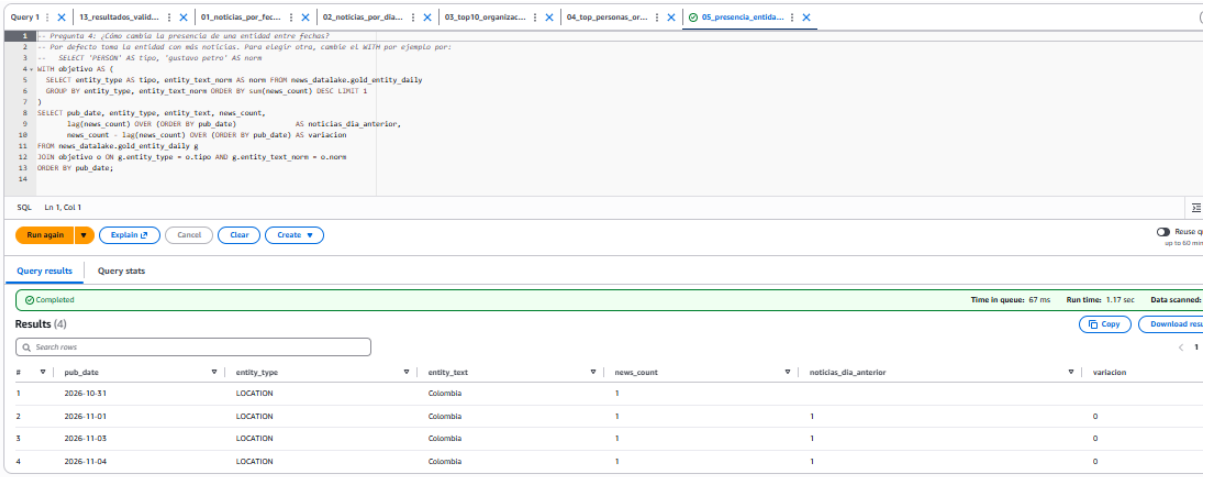
E19 · Pregunta 2: personas, organizaciones y lugares



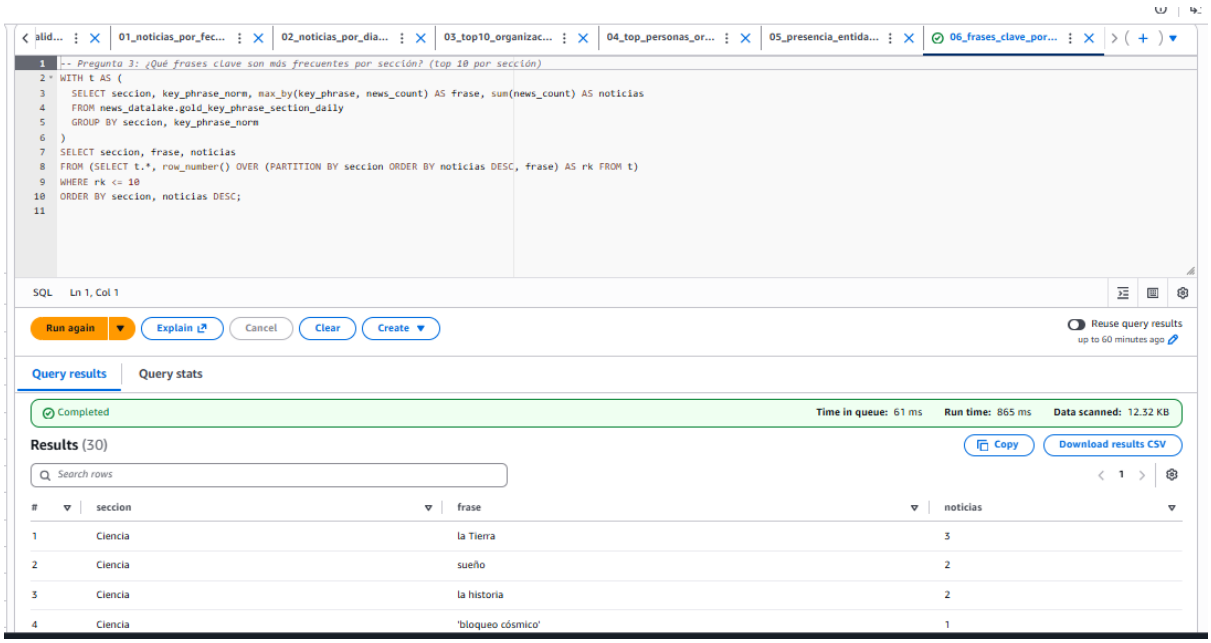
3	lugar	Bogotá	3
4	lugar	Cundinamarca	2
5	lugar	Cartagena	1
6	lugar	Ceres	1
7	lugar	Amazonía	1
8	lugar	Asia	1
9	lugar	Boyacá	1
10	lugar	Caracas	1
11	organizacion	NASA	2
12	organizacion	Servicio Geológico Colombiano	2
13	organizacion	Asocarbono	1
14	organizacion	Asociación Colombiana de Controladores de Tránsito Aéreo	1
15	organizacion	CAR lanza	1
16	organizacion	Cataruben	1
17	organizacion	Colombia	1
18	organizacion	Congreso	1
19	organizacion	ACDECTA	1
20	organizacion	Aerocivil	1
21	persona	colombianos	2
22	persona	Chalfie	1

22	persona	Chalfie	1
23	persona	Estados Unidos	1
24	persona	Juan Andrés López	1
25	persona	Marco Rubio	1
26	persona	Martin Chalfie	1
27	persona	María Fernanda Wilches	1
28	persona	Santiago Vargas	1
29	persona	Trichostigma guacharense	1
30	persona	CEO	1

E20 · Pregunta 4: presencia de una entidad entre fechas



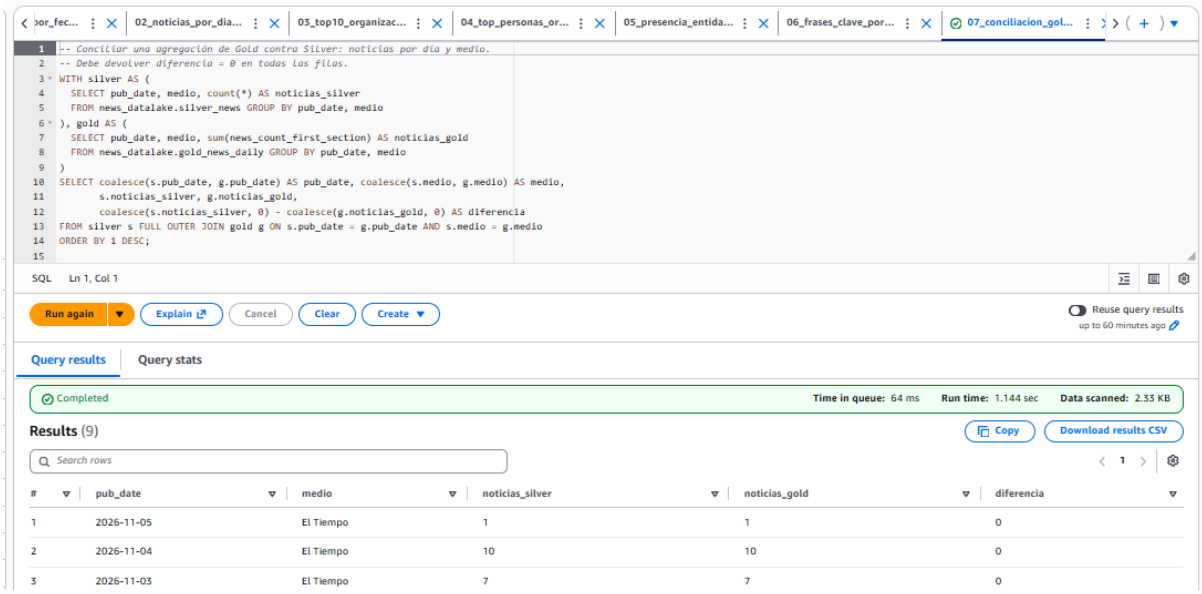
E21 · Pregunta 3: frases clave por sección



5	Ciencia	'demonios	1
6	Ciencia	1.500 kilogramos	1
7	Ciencia	191 elementos	1
8	Ciencia	22 años	1
9	Ciencia	47,3 millones de dólares	1
10	Ciencia	709	1
11	Medio Ambiente	Colombia	4
12	Medio Ambiente	la propuesta	3
13	Medio Ambiente	Cundinamarca	2
14	Medio Ambiente	agua	2
15	Medio Ambiente	carbono	2
16	Medio Ambiente	17	1
17	Medio Ambiente	19 congresistas	1
18	Medio Ambiente	23.776 hectáreas	1
19	Medio Ambiente	5,6	1
20	Medio Ambiente	Asocarbono	1
21	Viajar	Bogotá	3
22	Viajar	Los colombianos	2
23	Viajar	control aéreo	2
24	Viajar	los sistemas	2

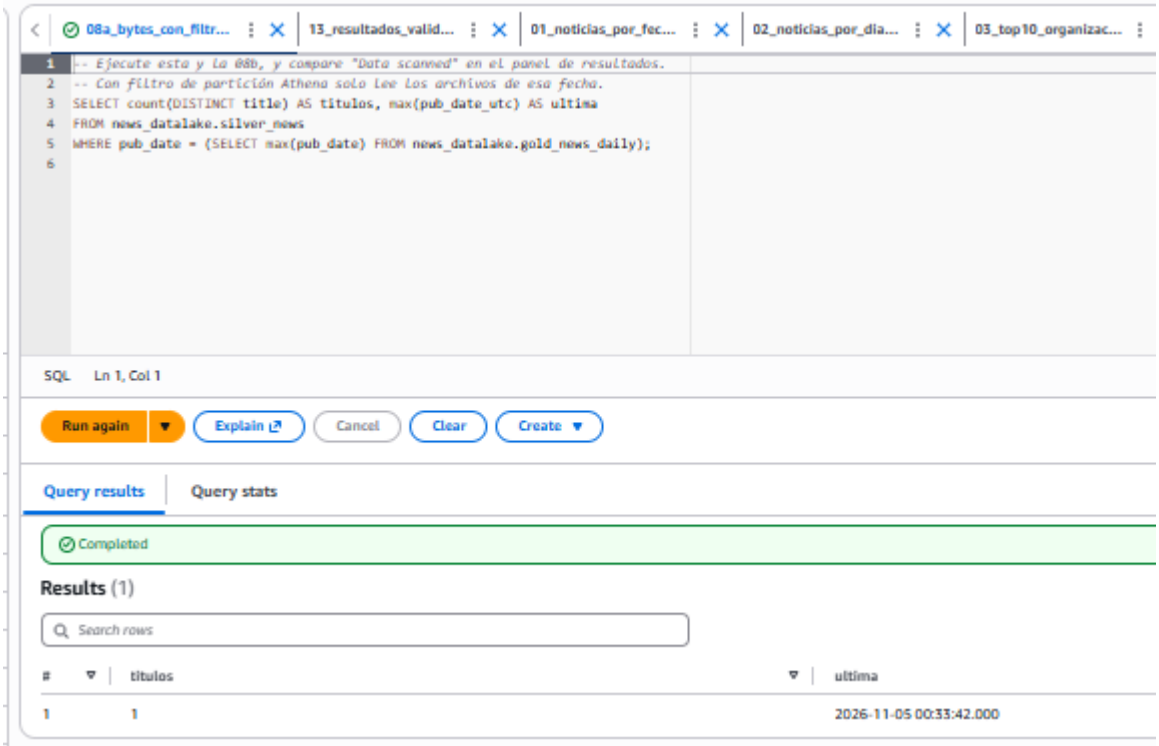
23	Viajar	control aéreo	2
24	Viajar	los sistemas	2
25	Viajar	vuelos	2
26	Viajar	(ACDECTA)	1
27	Viajar	200 metros	1
28	Viajar	337.000 reservas	1
29	Viajar	38 %	1
30	Viajar	51 países	1

E22 · Conciliación Gold vs. Silver

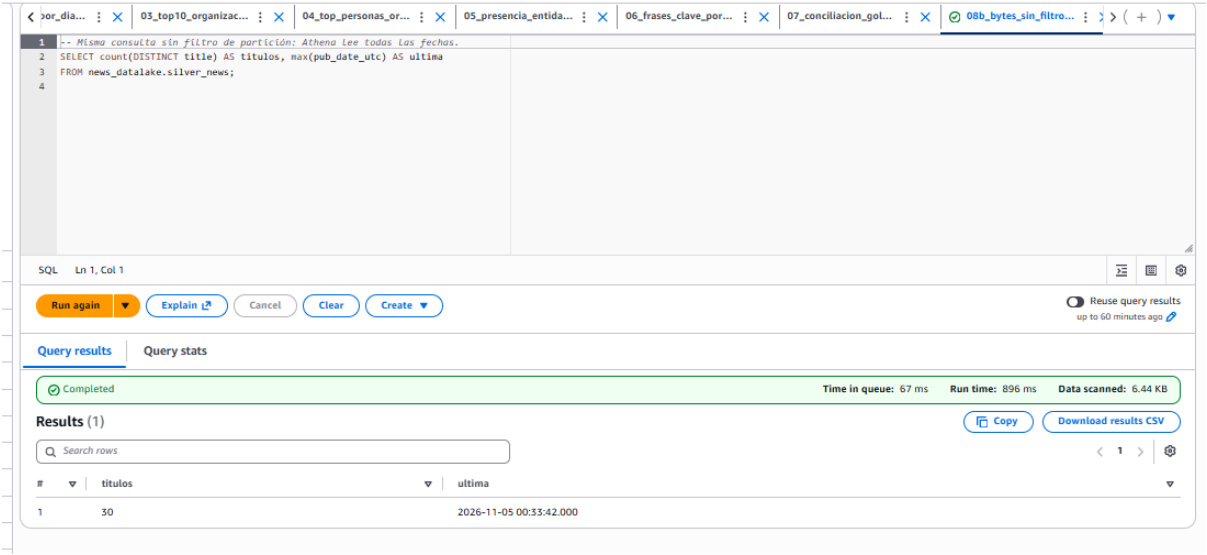


#	pub_date	medio	noticias_silver	noticias_gold	diferencia
4	2026-11-02	El Tiempo	1	1	0
5	2026-11-01	El Tiempo	2	2	0
6	2026-10-31	El Tiempo	2	2	0
7	2026-10-30	El Tiempo	1	1	0
8	2026-10-29	El Tiempo	4	4	0
9	2026-10-28	El Tiempo	2	2	0

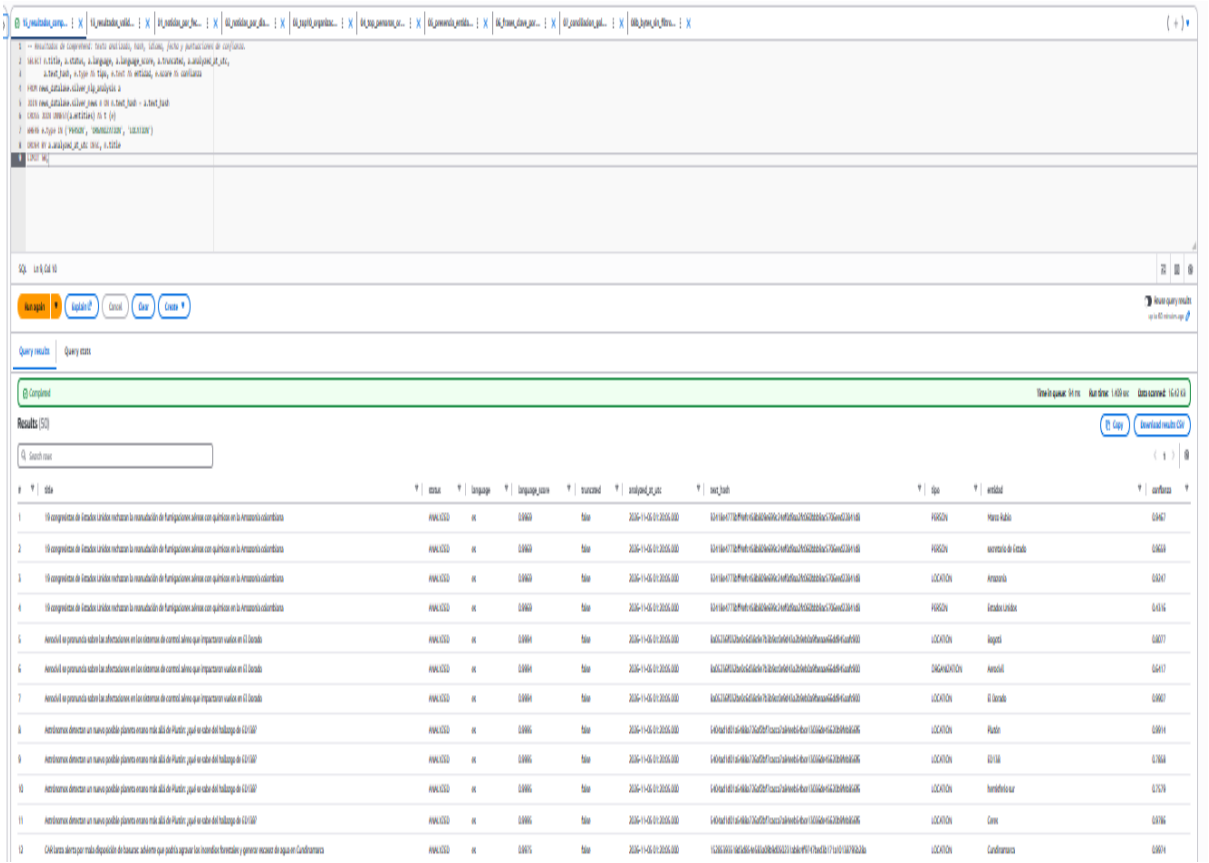
E23 · Bytes escaneados con filtro de partición



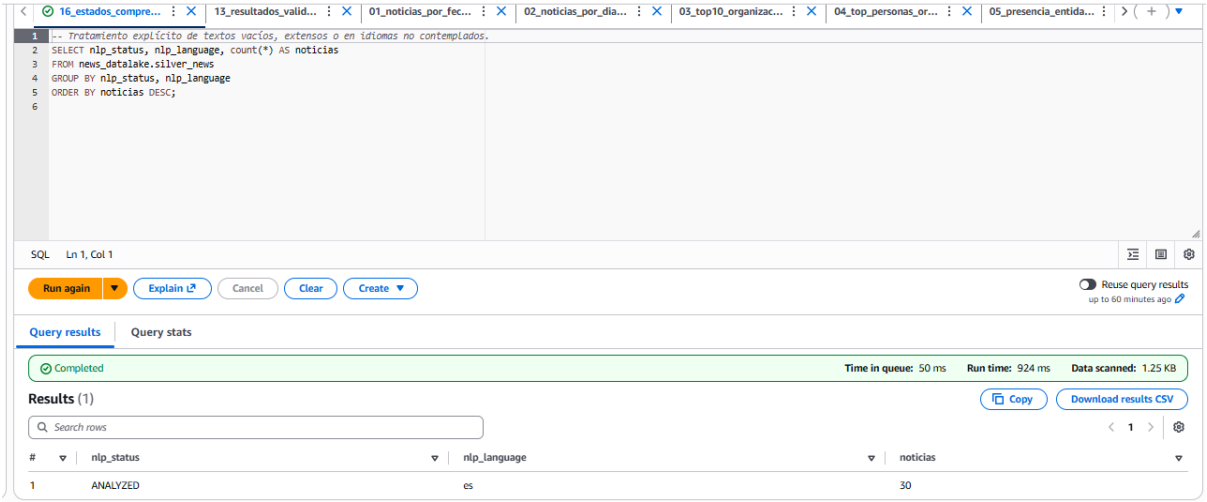
E24 · Bytes escaneados sin filtro de partición



E25 · Resultados de Comprehend



E26 · Estados de procesamiento de Comprehend



```
-- Tratamiento explícito de textos vacíos, extensos o en idiomas no contemplados.
SELECT nlp_status, nlp_language, count(*) AS noticias
FROM news_datalake.silver_news
GROUP BY nlp_status, nlp_language
ORDER BY noticias DESC;
```

Run again | Explain | Cancel | Clear | Create | Reuse query results (up to 60 minutes ago)

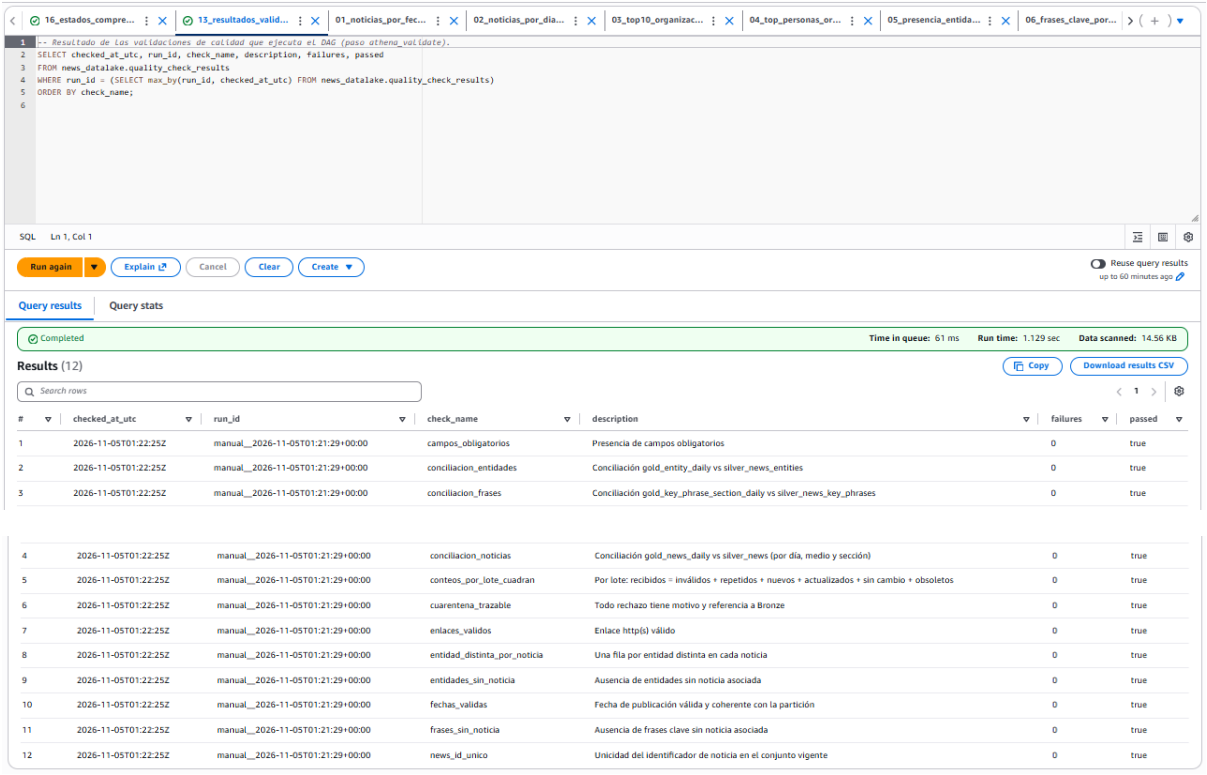
Query results | Query stats

Completed — Time in queue: 50 ms — Run time: 924 ms — Data scanned: 1.25 KB

Results (1) — Copy | Download results CSV

#	nlp_status	nlp_language	noticias
1	ANALYZED	es	30

E27 · Resultados de las validaciones de calidad



```
-- Resultado de las validaciones de calidad que ejecuta el DAG (paso athena_validate).
SELECT checked_at_utc, run_id, check_name, description, failures, passed
FROM news_datalake.quality_check_results
WHERE run_id = (SELECT max_by(run_id, checked_at_utc) FROM news_datalake.quality_check_results)
ORDER BY check_name;
```

Run again | Explain | Cancel | Clear | Create | Reuse query results (up to 60 minutes ago)

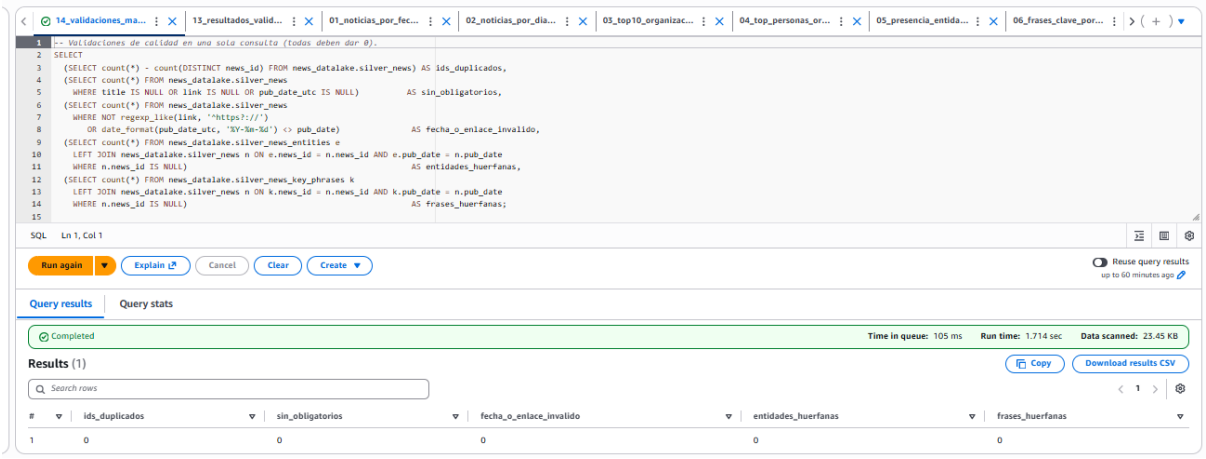
Query results | Query stats

Completed — Time in queue: 61 ms — Run time: 1.129 sec — Data scanned: 14.56 KB

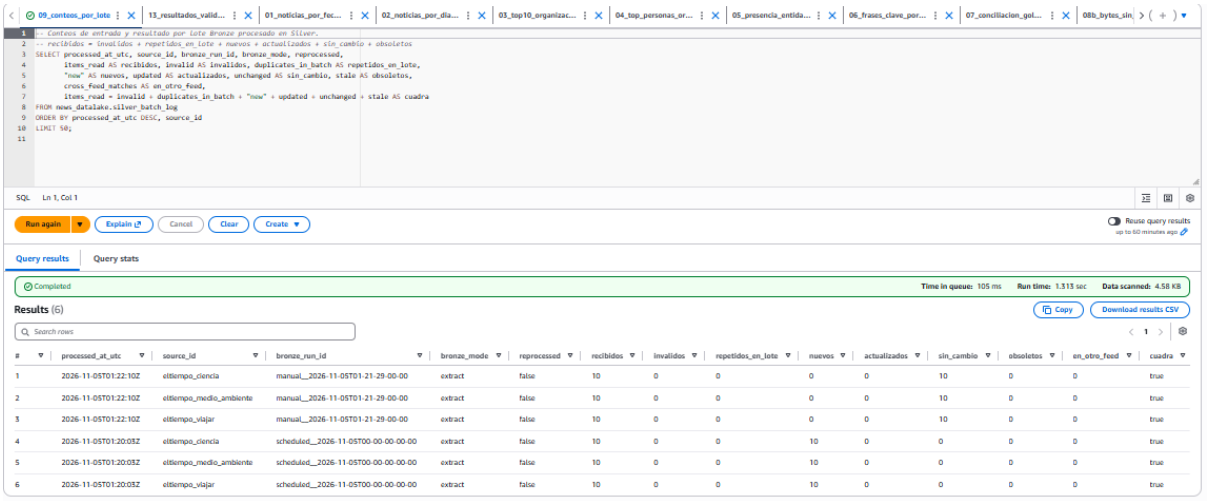
Results (12) — Copy | Download results CSV

#	checked_at_utc	run_id	check_name	description	failures	passed
1	2026-11-05T01:22:25Z	manual__2026-11-05T01:21:29+00:00	campos_obligatorios	Presencia de campos obligatorios	0	true
2	2026-11-05T01:22:25Z	manual__2026-11-05T01:21:29+00:00	conciliacion_entidades	Conciliación gold_entity_daily vs silver_news_entities	0	true
3	2026-11-05T01:22:25Z	manual__2026-11-05T01:21:29+00:00	conciliacion_frases	Conciliación gold_key_phrase_section_daily vs silver_news_key_phrases	0	true
4	2026-11-05T01:22:25Z	manual__2026-11-05T01:21:29+00:00	conciliacion_noticias	Conciliación gold_news_daily vs silver_news (por día, medio y sección)	0	true
5	2026-11-05T01:22:25Z	manual__2026-11-05T01:21:29+00:00	conteos_por_lote_cuadran	Por lote: recibidos = inválidos + repetidos + nuevos + actualizados + sin cambio + obsoletos	0	true
6	2026-11-05T01:22:25Z	manual__2026-11-05T01:21:29+00:00	cuarentena_trazable	Todo rechazo tiene motivo y referencia a Bronze	0	true
7	2026-11-05T01:22:25Z	manual__2026-11-05T01:21:29+00:00	enlaces_validos	Enlace http(s) válido	0	true
8	2026-11-05T01:22:25Z	manual__2026-11-05T01:21:29+00:00	entidad_distinta_por_noticia	Una fila por entidad distinta en cada noticia	0	true
9	2026-11-05T01:22:25Z	manual__2026-11-05T01:21:29+00:00	entidades_sin_noticia	Ausencia de entidades sin noticia asociada	0	true
10	2026-11-05T01:22:25Z	manual__2026-11-05T01:21:29+00:00	fechas_validas	Fecha de publicación válida y coherente con la partición	0	true
11	2026-11-05T01:22:25Z	manual__2026-11-05T01:21:29+00:00	frases_sin_noticia	Ausencia de frases clave sin noticia asociada	0	true
12	2026-11-05T01:22:25Z	manual__2026-11-05T01:21:29+00:00	news_id_unico	Unicidad del identificador de noticia en el conjunto vigente	0	true

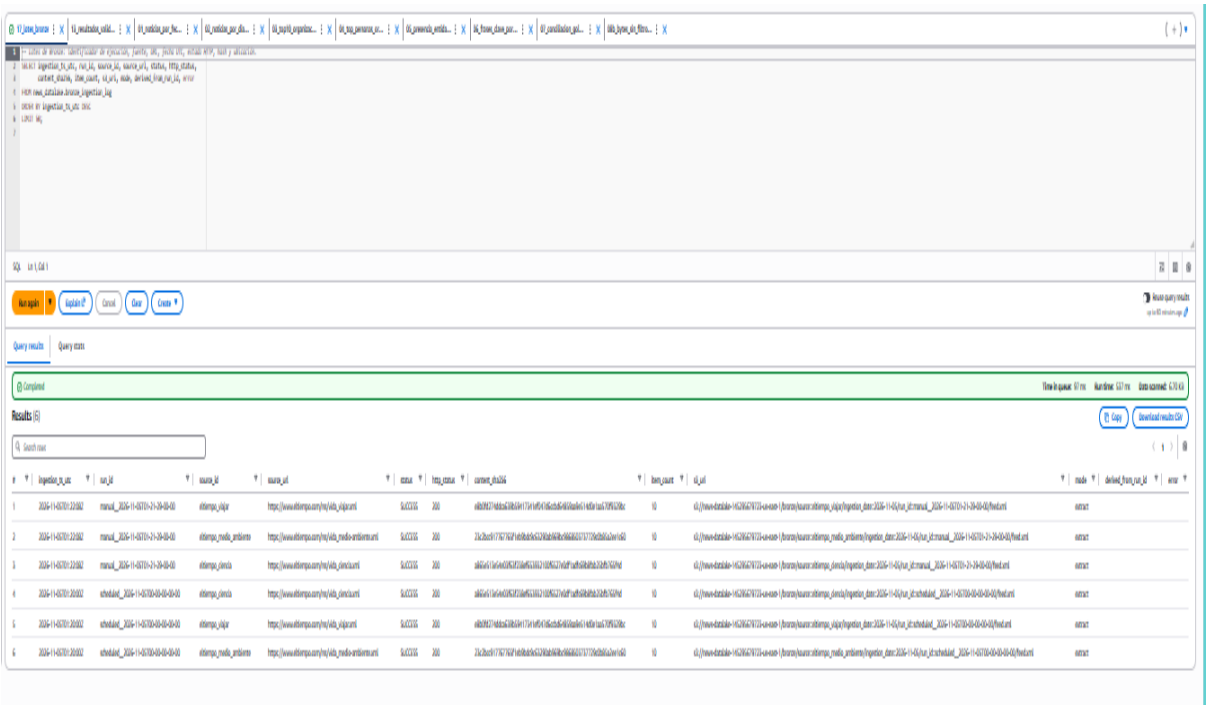
E28 · Validaciones manuales en una consulta



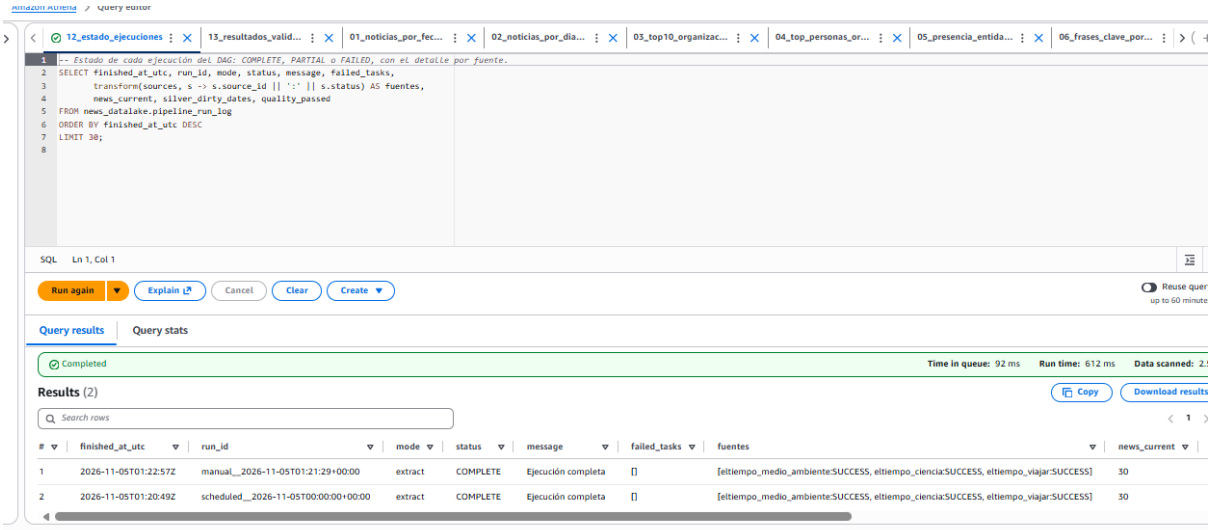
E29 · Conteos de entrada y resultado por lote

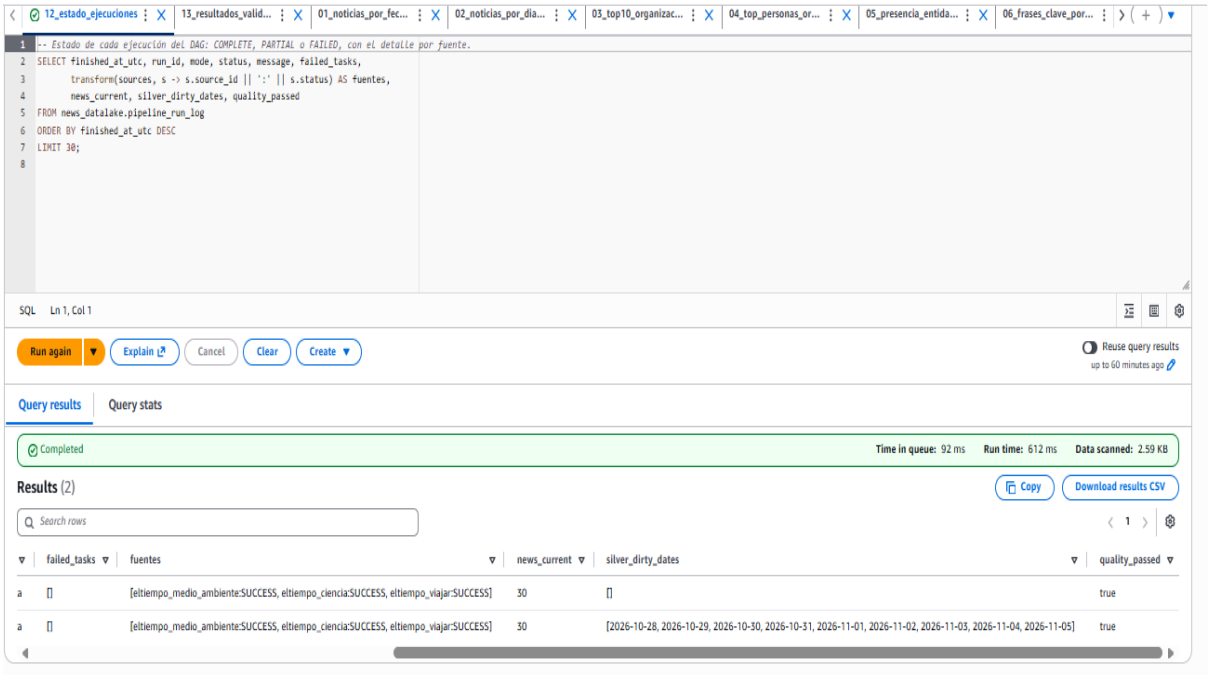


E30 · Registro de lotes en Bronze



E31 · Estado de las ejecuciones





5. Escenarios de calidad, incrementalidad y recuperación (4.5)

Cada escenario muestra el resultado esperado de la tabla 4.5 del enunciado.

5.1 Registros defectuosos

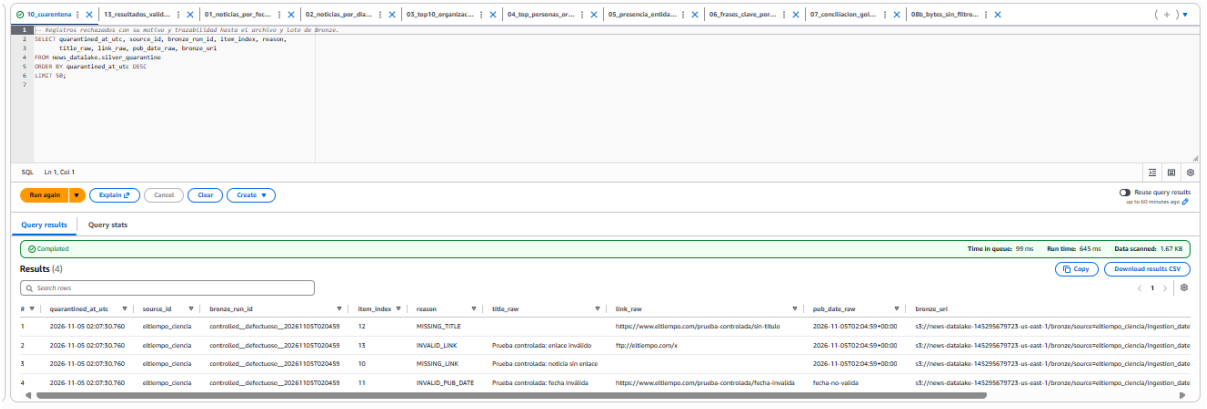
Resultado esperado: Rechazos identificados, con motivo y trazabilidad hasta Bronze.

E32 · Creación del lote con registros defectuosos

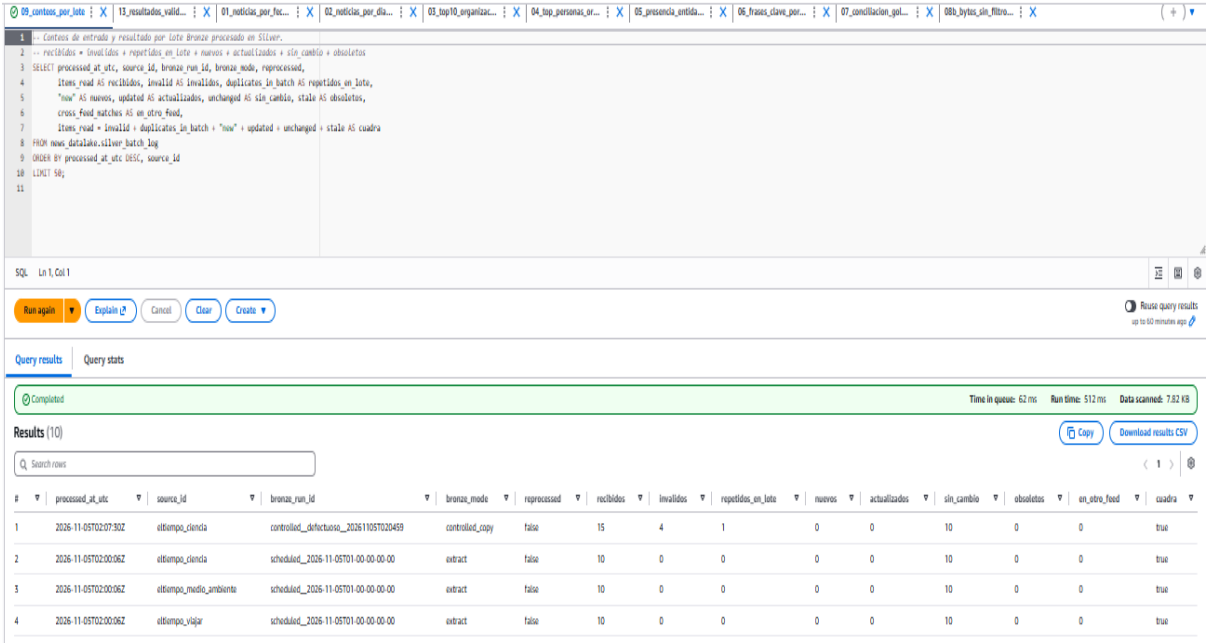
```
Starting session with SessionId: user_cli-h3ovglxdnp9v4vricth2y5bcny
sh-5.2$ sudo -iu airflow
[airflow@ip-172-31-76-196 ~]$ cd /opt/news-datalake
[airflow@ip-172-31-76-196 news-datalake]$ py -m news_pipeline.scenarios --bucket $DATALAKE_BUCKET --source eltiempo_ciencia --scenario defectuoso
Lote controlado creado: run_id=controlled__defectuoso__20261105T020459
  basado en: scheduled__2026-11-05T01-00-00-00-00  (s3://news-datalake-145295679723-us-east-1/bronze/source=eltiempo_ciencia/ingestion_date=2026-11-05/run_id=scheduled__20
26-11-05T01-00-00-00-00/feed.xml)
  nuevo:     s3://news-datalake-145295679723-us-east-1/bronze/source=eltiempo_ciencia/ingestion_date=2026-11-05/run_id=controlled__defectuoso__20261105T020459/feed.xml
  cambio:    Agregados registros defectuosos: MISSING_LINK, INVALID_PUB_DATE, MISSING_TITLE, INVALID_LINK, DUPLICATE_IN_BATCH

Procéselo desde Airflow (sin consultar los RSS):
  airflow dags trigger news_datalake_pipeline --conf '{"mode": "reprocess", "reprocess_run_id": "controlled__defectuoso__20261105T020459"}'
[airflow@ip-172-31-76-196 news-datalake]$
```

E33 · Registros en cuarentena con su motivo



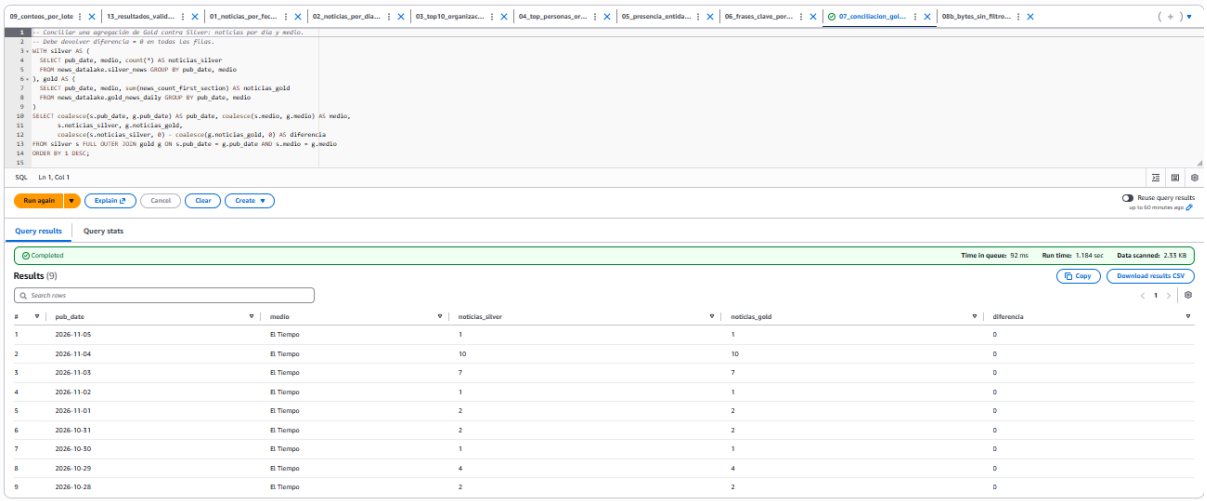
E34 · Conteos del lote defectuoso

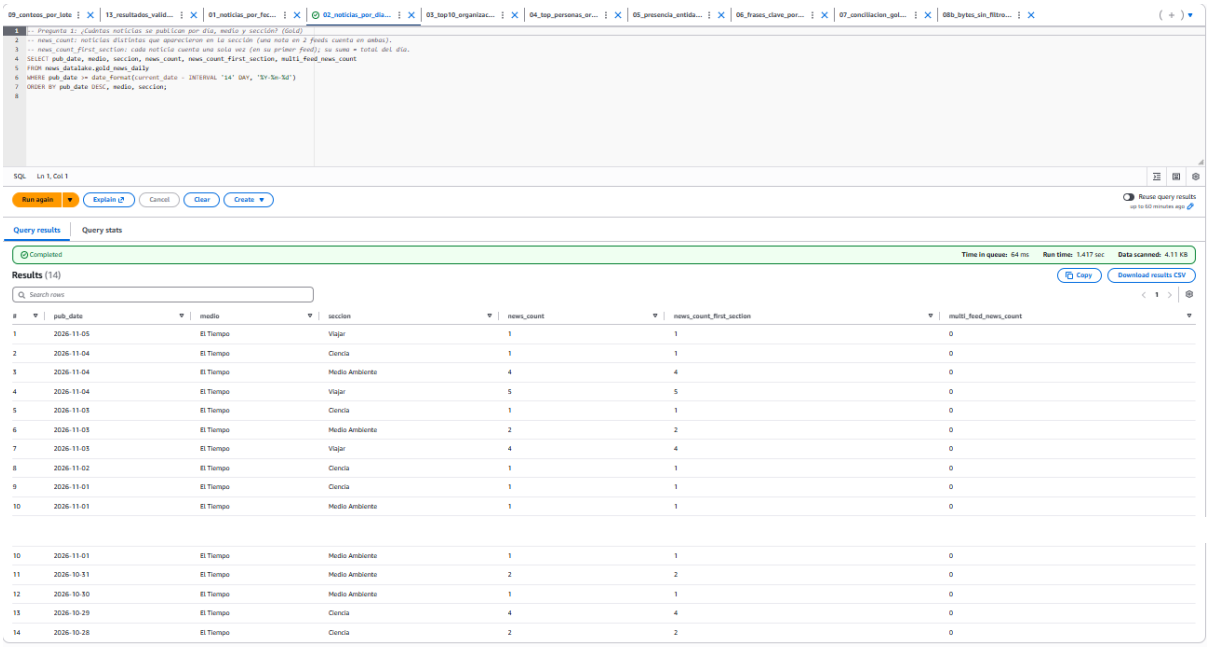


5.2 Repetición de un lote exitoso

Resultado esperado: Sin duplicados en Silver ni doble conteo en Gold.

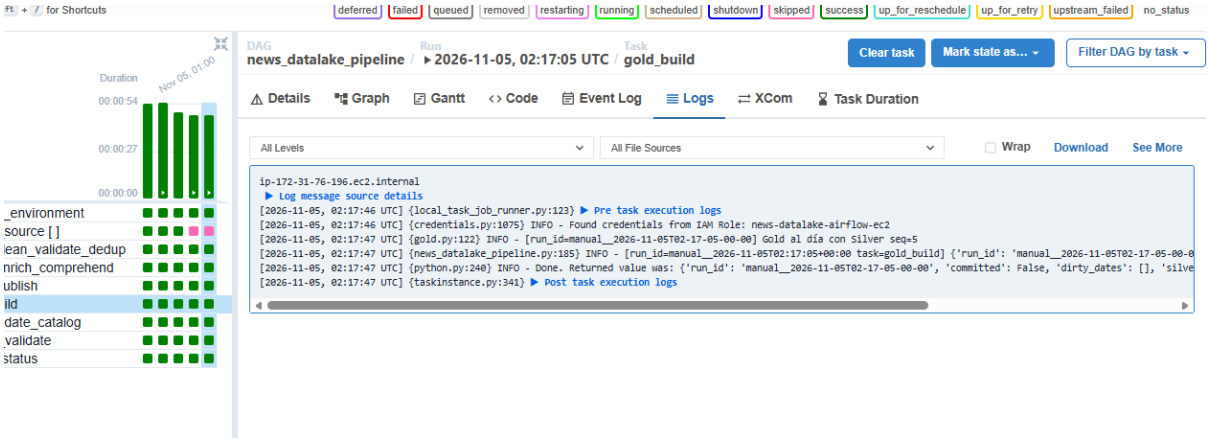
E35 · Indicadores antes de repetir el lote



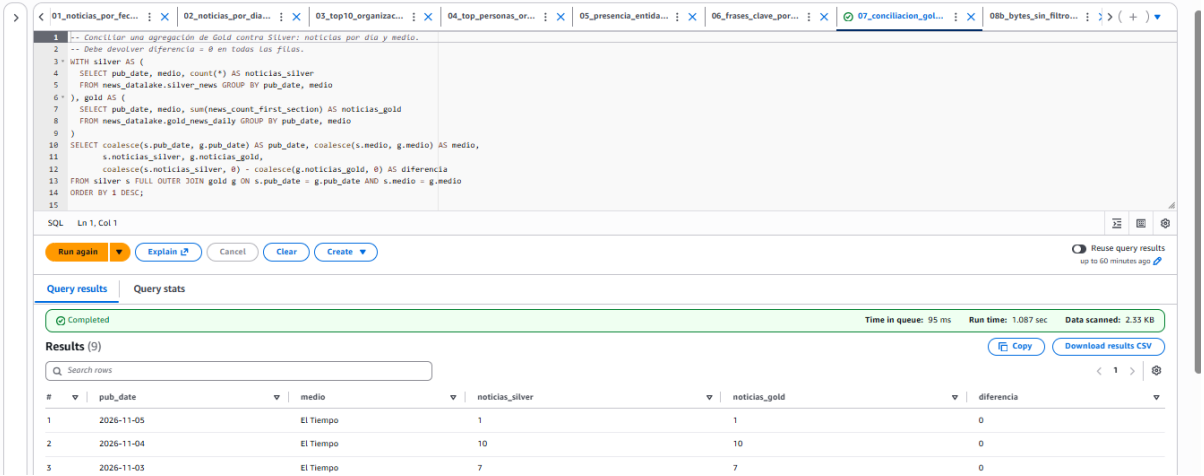


E36 · Log: la repetición no reescribe particiones



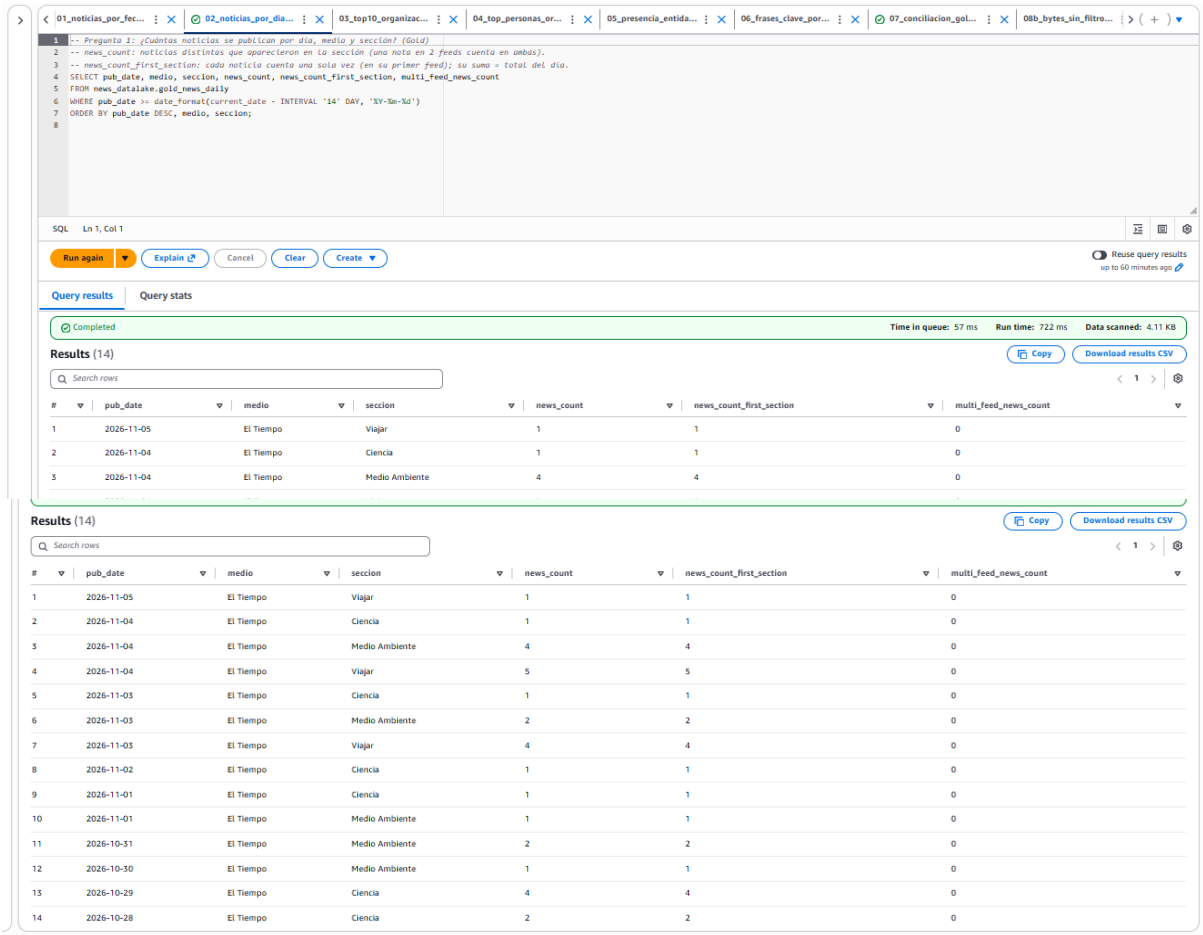


E37 · Indicadores después de repetir el lote



Search rows

#	pub_date	medio	noticias_silver	noticias_gold	diferencia
1	2026-11-05	El Tiempo	1	1	0
2	2026-11-04	El Tiempo	10	10	0
3	2026-11-03	El Tiempo	7	7	0
4	2026-11-02	El Tiempo	1	1	0
5	2026-11-01	El Tiempo	2	2	0
6	2026-10-31	El Tiempo	2	2	0
7	2026-10-30	El Tiempo	1	1	0
8	2026-10-29	El Tiempo	4	4	0
9	2026-10-28	El Tiempo	2	2	0



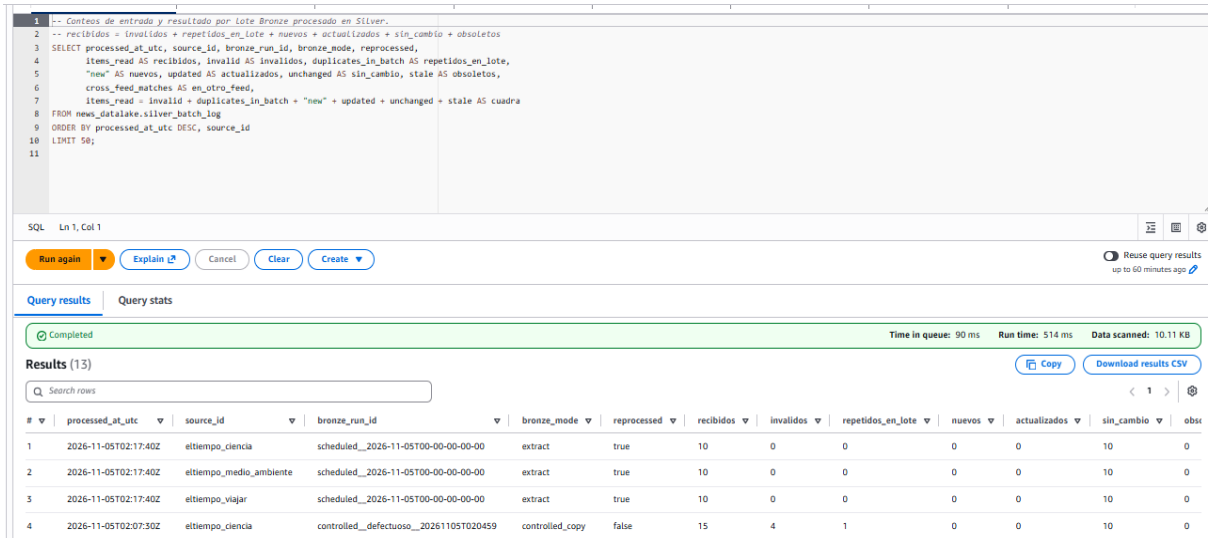
#	pub_date	medio	seccion	news_count	news_count_first_section	multi_feed_news_count
1	2026-11-05	El Tiempo	Viajar	1	1	0
2	2026-11-04	El Tiempo	Ciencia	1	1	0
3	2026-11-04	El Tiempo	Medio Ambiente	4	4	0

Results (14)

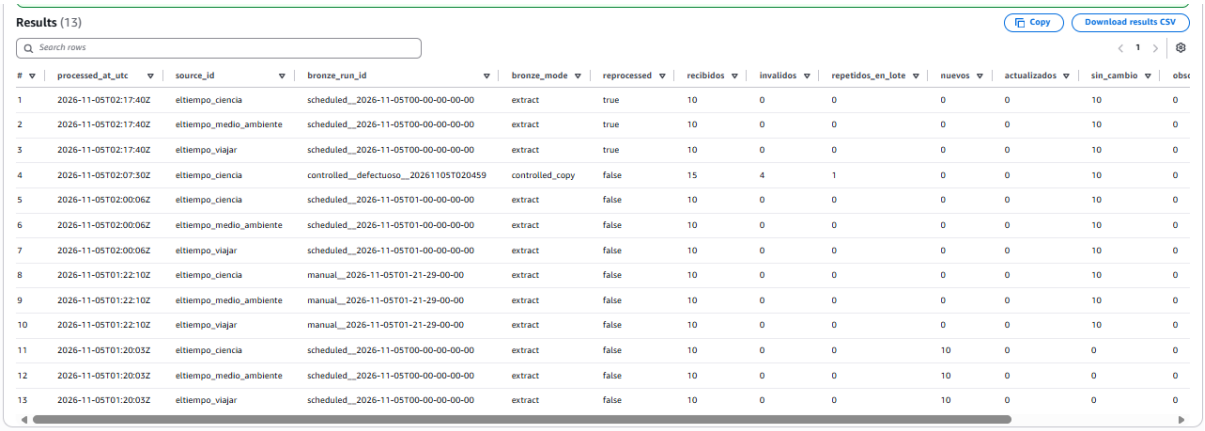
Search rows

#	pub_date	medio	seccion	news_count	news_count_first_section	multi_feed_news_count
1	2026-11-05	El Tiempo	Viajar	1	1	0
2	2026-11-04	El Tiempo	Ciencia	1	1	0
3	2026-11-04	El Tiempo	Medio Ambiente	4	4	0
4	2026-11-04	El Tiempo	Viajar	5	5	0
5	2026-11-03	El Tiempo	Ciencia	1	1	0
6	2026-11-03	El Tiempo	Medio Ambiente	2	2	0
7	2026-11-03	El Tiempo	Viajar	4	4	0
8	2026-11-02	El Tiempo	Ciencia	1	1	0
9	2026-11-01	El Tiempo	Ciencia	1	1	0
10	2026-11-01	El Tiempo	Medio Ambiente	1	1	0
11	2026-10-31	El Tiempo	Medio Ambiente	2	2	0
12	2026-10-30	El Tiempo	Medio Ambiente	1	1	0
13	2026-10-29	El Tiempo	Ciencia	4	4	0
14	2026-10-28	El Tiempo	Ciencia	2	2	0

E38 · Lote repetido marcado como reprocesado



#	processed_at_utc	source_id	bronze_run_id	bronze_mode	reprocessed	recibidos	invalidos	repetidos_en_lote	nuevos	actualizados	sin_cambio	obs
1	2026-11-05T02:17:40Z	eltiempo_ciencia	scheduled__2026-11-05T00-00-00-00-00	extract	true	10	0	0	0	0	10	0
2	2026-11-05T02:17:40Z	eltiempo_medio_ambiente	scheduled__2026-11-05T00-00-00-00-00	extract	true	10	0	0	0	0	10	0
3	2026-11-05T02:17:40Z	eltiempo_viajar	scheduled__2026-11-05T00-00-00-00-00	extract	true	10	0	0	0	0	10	0
4	2026-11-05T02:07:30Z	eltiempo_ciencia	controlled__defectuoso__20261105T020459	controlled_copy	false	15	4	1	0	0	10	0



Results (13)

Copy | Download results CSV

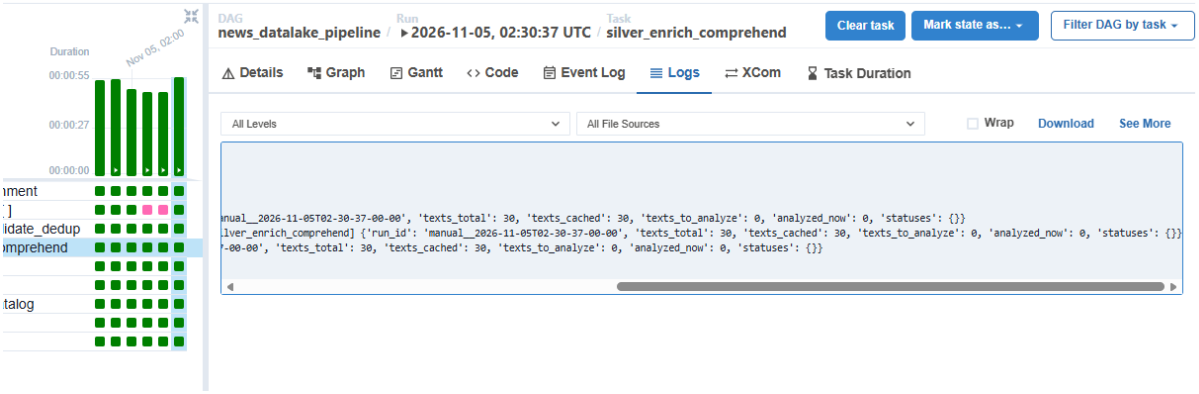
Search rows

#	processed_at_utc	source_id	bronze_run_id	bronze_mode	reprocessed	recibidos	invalidos	repetidos_en_lote	nuevos	actualizados	sin_cambio	obsc
1	2026-11-05T02:17:40Z	eltiempo_ciencia	scheduled__2026-11-05T00-00-00-00-00	extract	true	10	0	0	0	0	10	0
2	2026-11-05T02:17:40Z	eltiempo_medio_ambiente	scheduled__2026-11-05T00-00-00-00-00	extract	true	10	0	0	0	0	10	0
3	2026-11-05T02:17:40Z	eltiempo_viajar	scheduled__2026-11-05T00-00-00-00-00	extract	true	10	0	0	0	0	10	0
4	2026-11-05T02:07:30Z	eltiempo_ciencia	controlled__defectuoso__20261105T020459	controlled_copy	false	15	4	1	0	0	10	0
5	2026-11-05T02:00:06Z	eltiempo_ciencia	scheduled__2026-11-05T01-00-00-00-00	extract	false	10	0	0	0	0	10	0
6	2026-11-05T02:00:06Z	eltiempo_medio_ambiente	scheduled__2026-11-05T01-00-00-00-00	extract	false	10	0	0	0	0	10	0
7	2026-11-05T02:00:06Z	eltiempo_viajar	scheduled__2026-11-05T01-00-00-00-00	extract	false	10	0	0	0	0	10	0
8	2026-11-05T01:22:10Z	eltiempo_ciencia	manual__2026-11-05T01-21-29-00-00	extract	false	10	0	0	0	0	10	0
9	2026-11-05T01:22:10Z	eltiempo_medio_ambiente	manual__2026-11-05T01-21-29-00-00	extract	false	10	0	0	0	0	10	0
10	2026-11-05T01:22:10Z	eltiempo_viajar	manual__2026-11-05T01-21-29-00-00	extract	false	10	0	0	0	0	10	0
11	2026-11-05T01:20:03Z	eltiempo_ciencia	scheduled__2026-11-05T00-00-00-00-00	extract	false	10	0	0	10	0	0	0
12	2026-11-05T01:20:03Z	eltiempo_medio_ambiente	scheduled__2026-11-05T00-00-00-00-00	extract	false	10	0	0	10	0	0	0
13	2026-11-05T01:20:03Z	eltiempo_viajar	scheduled__2026-11-05T00-00-00-00-00	extract	false	10	0	0	10	0	0	0

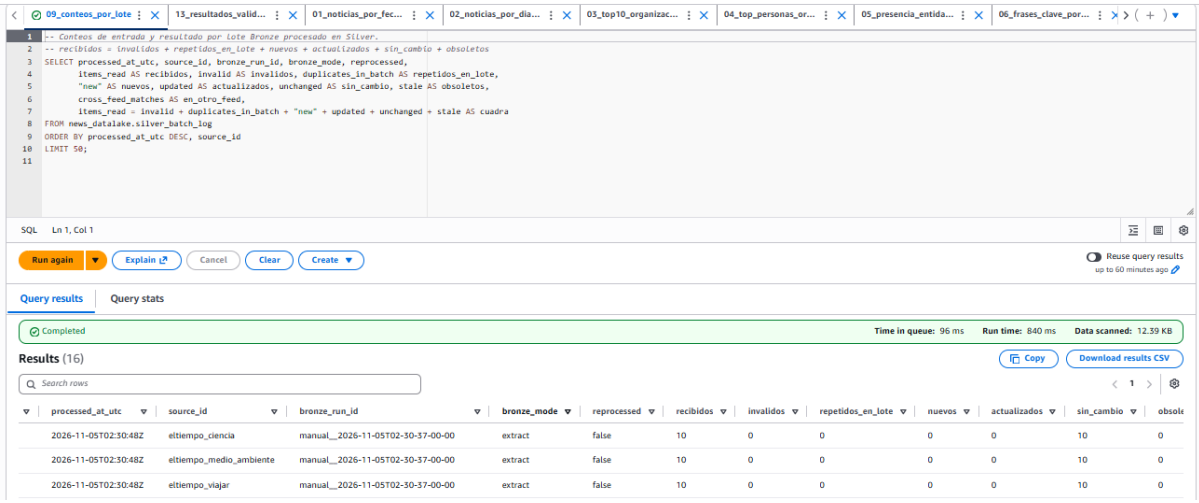
5.3 Nuevo lote incremental

Resultado esperado: Incorporación de noticias nuevas sin reprocesar innecesariamente las existentes.

E39 · Log: Comprehend solo analiza textos nuevos



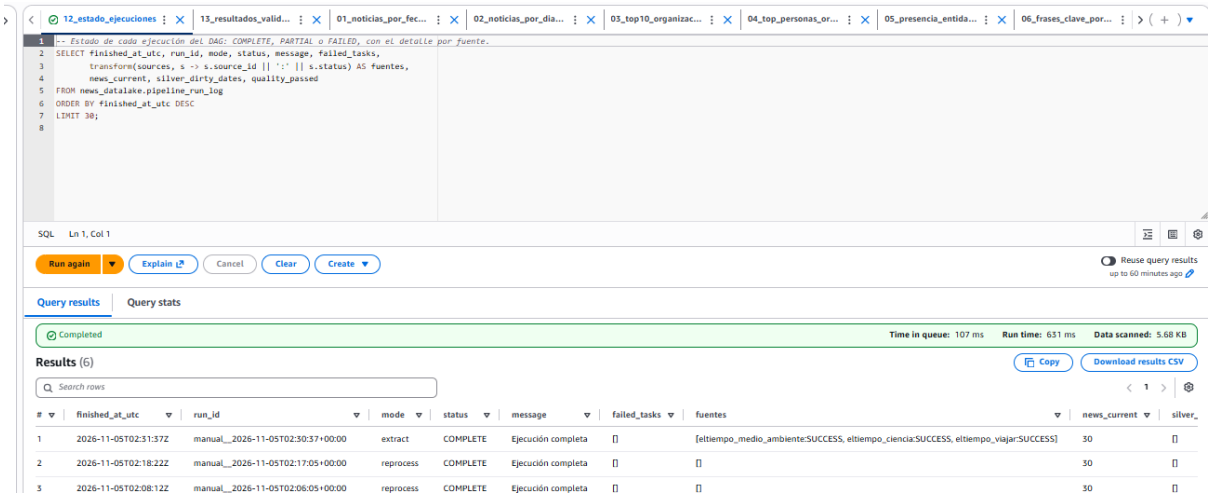
E40 · Conteos del nuevo lote incremental

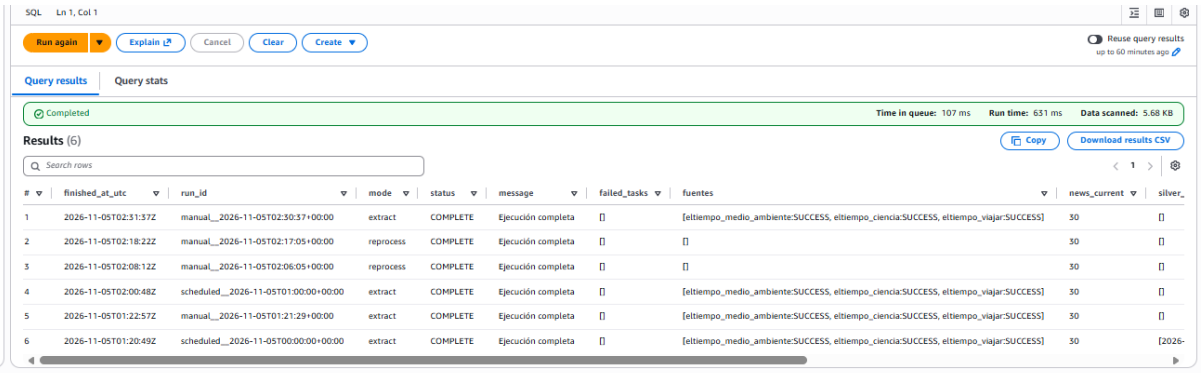


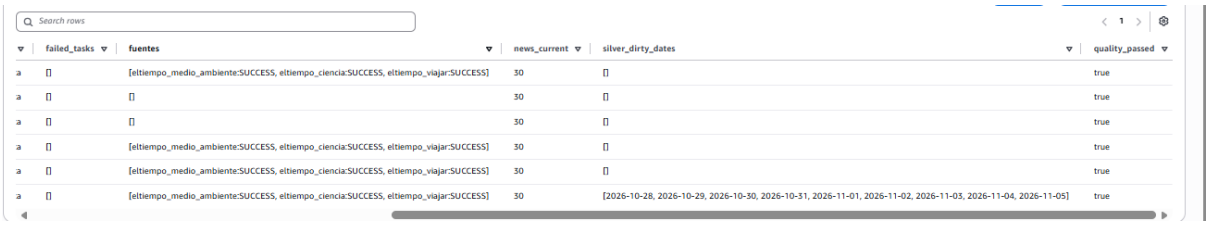
processed_at_utc	source_id	bronze_run_id	bronze_mode	reprocessed	recibidos	invalidos	repetidos_en_lote	nuevos	actualizados	sin_cambio	obsole
2026-11-05T02:30:48Z	eltiempo_ciencia	manual__2026-11-05T02-30-57-00-00	extract	false	10	0	0	0	0	10	0
2026-11-05T02:30:48Z	eltiempo_medio_ambiente	manual__2026-11-05T02-30-57-00-00	extract	false	10	0	0	0	0	10	0
2026-11-05T02:30:48Z	eltiempo_viajar	manual__2026-11-05T02-30-57-00-00	extract	false	10	0	0	0	0	10	0



E41 · Solo se reescriben las fechas que cambiaron







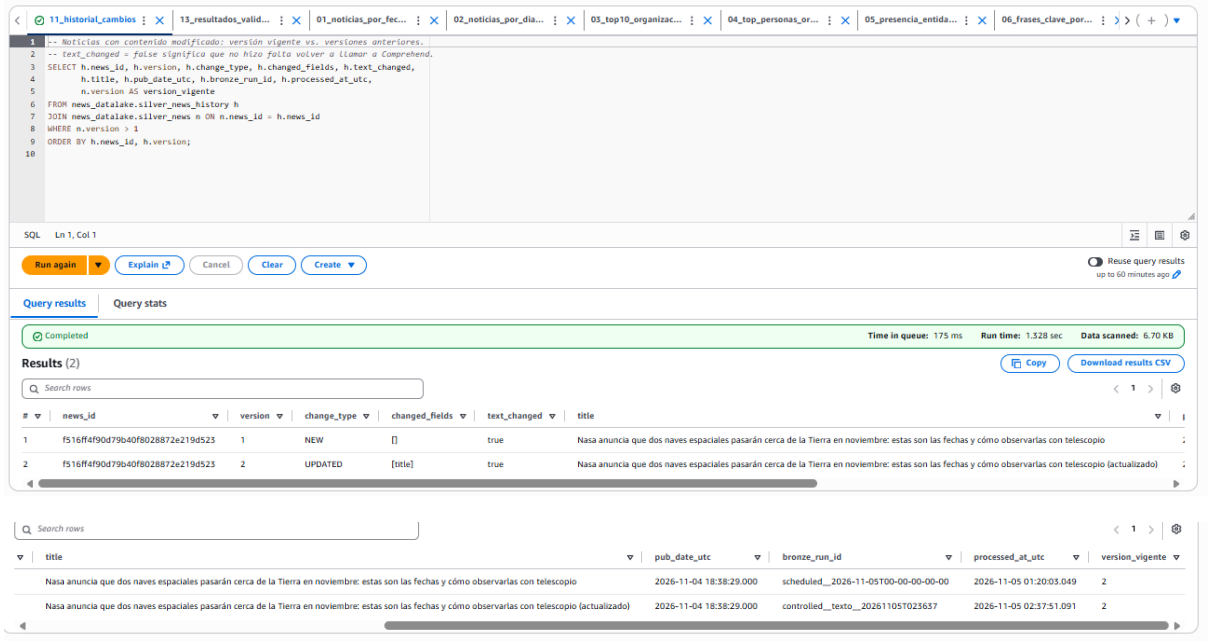
5.4 Noticia con contenido modificado

Resultado esperado: Actualización de la versión vigente y nuevo enriquecimiento únicamente cuando cambia el texto analizado.

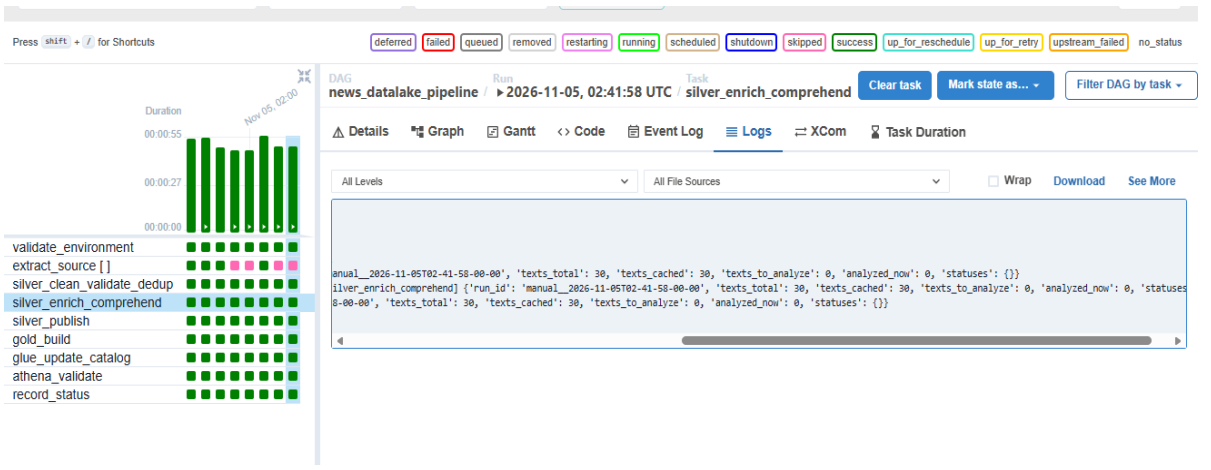
E42 · Log: un solo texto enviado a Comprehend



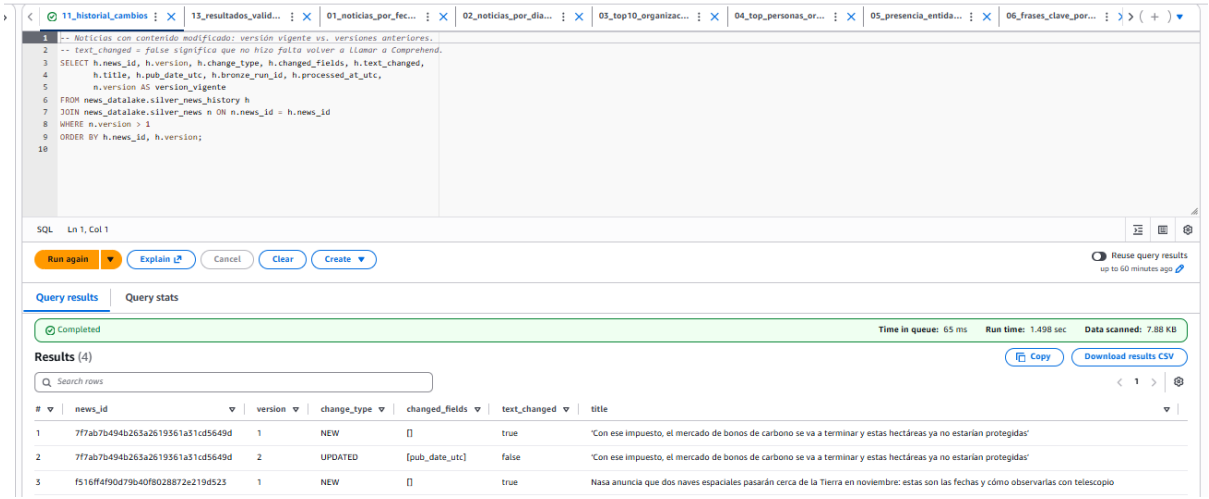
E43 · Historial: cambio de título (texto modificado)

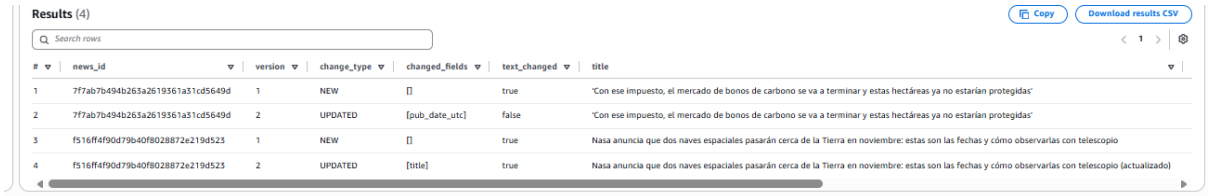


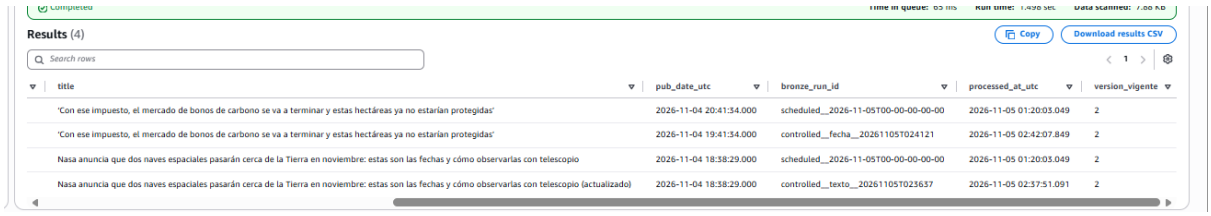
E44 · Log: ningún texto enviado a Comprehend



E45 · Historial: cambio solo de fecha



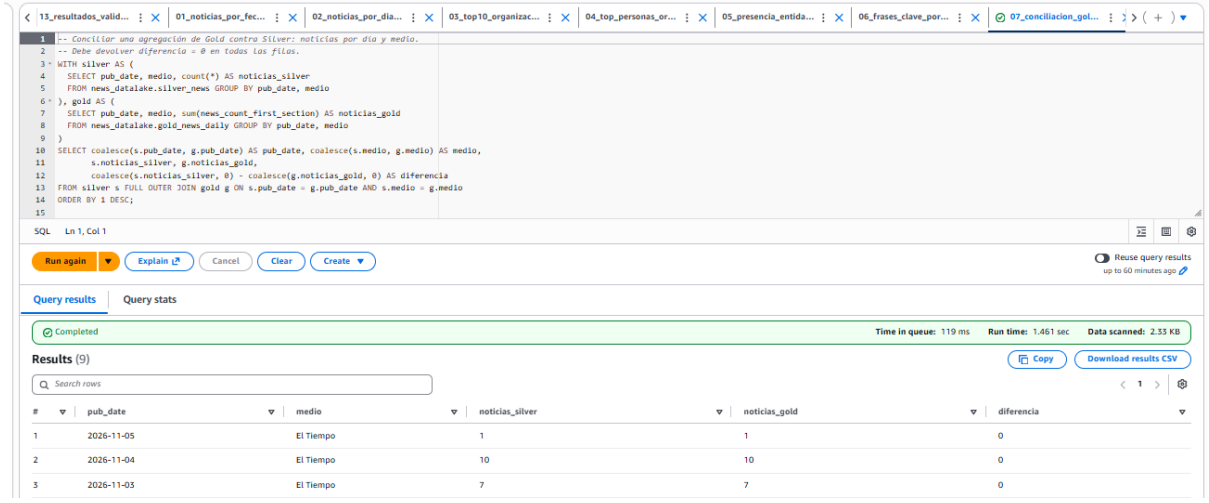


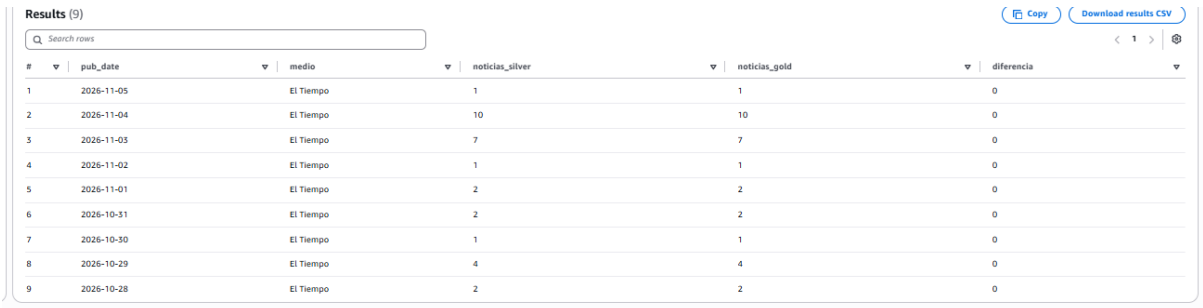


5.5 Fallo controlado y reejecución

Resultado esperado: Recuperación sin pérdida ni duplicación de resultados.

E46 · Indicadores antes del fallo





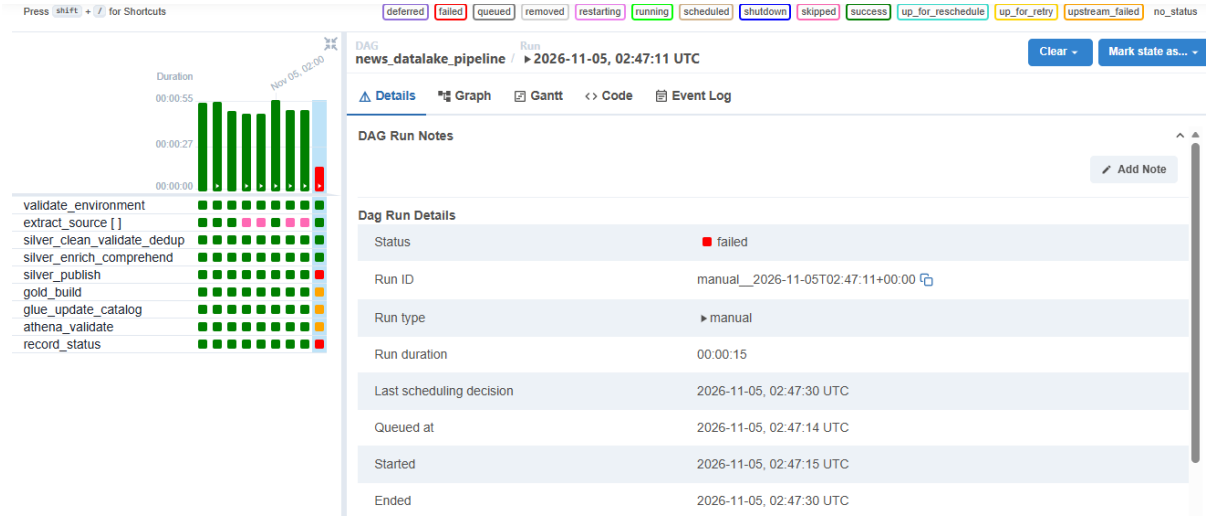
Results (9)

Copy | Download results CSV

Search rows

#	pub_date	medio	noticias_silver	noticias_gold	diferencia
1	2026-11-05	El Tiempo	1	1	0
2	2026-11-04	El Tiempo	10	10	0
3	2026-11-03	El Tiempo	7	7	0
4	2026-11-02	El Tiempo	1	1	0
5	2026-11-01	El Tiempo	2	2	0
6	2026-10-31	El Tiempo	2	2	0
7	2026-10-30	El Tiempo	1	1	0
8	2026-10-29	El Tiempo	4	4	0
9	2026-10-28	El Tiempo	2	2	0

E47 · DAG con silver_publish fallido



Press shift + / for Shortcuts

deferred | failed | queued | removed | restarting | running | scheduled | shutdown | skipped | success | up_for_reschedule | up_for_retry | upstream_failed | no_status

Duration

00:00:55

00:00:27

00:00:00

Nov 05, 02:00

validate_environment
extract_source [ ]
silver_clean_validate_dedup
silver_enrich_comprehend
silver_publish
gold_build
glue_update_catalog
athena_validate
record_status

DAG news_datalake_pipeline / Run ▸2026-11-05, 02:47:11 UTC

Clear | Mark state as...

Details | Graph | Gantt | Code | Event Log

DAG Run Notes

Add Note

Dag Run Details

Status	failed
Run ID	manual__2026-11-05T02:47:11+00:00
Run type	▸manual
Run duration	00:00:15
Last scheduling decision	2026-11-05, 02:47:30 UTC
Queued at	2026-11-05, 02:47:14 UTC
Started	2026-11-05, 02:47:15 UTC
Ended	2026-11-05, 02:47:30 UTC

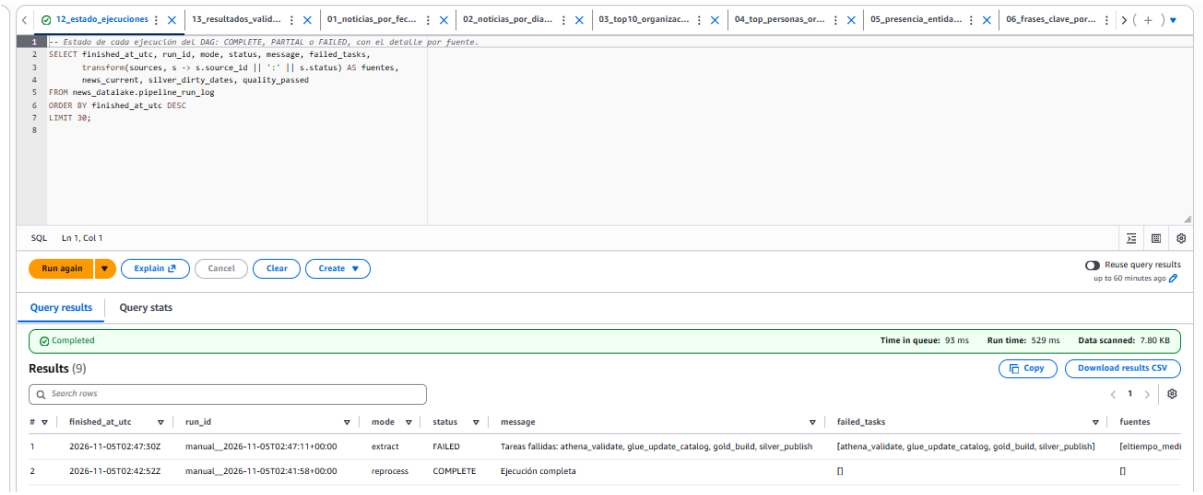
E48 · Log del fallo simulado



silver_clean_validate_dedup
silver_enrich_comprehend
silver_publish
gold_build
glue_update_catalog
athena_validate
record_status

```
                ^^^^^^^^^^^^^^^^^^^^^^^^^^
  File "/opt/airflow/venv/lib64/python3.11/site-packages/airflow/models/baseoperator.py", line 424, in wrapper
    return func(self, *args, **kwargs)
           ^^^^^^^^^^^^^^^^^^^^^^^^^^^
  File "/opt/airflow/venv/lib64/python3.11/site-packages/airflow/decorators/base.py", line 266, in execute
    return_value = super().execute(context)
                   ^^^^^^^^^^^^^^^^^^^^^^^^
  File "/opt/airflow/venv/lib64/python3.11/site-packages/airflow/models/baseoperator.py", line 424, in wrapper
    return func(self, *args, **kwargs)
           ^^^^^^^^^^^^^^^^^^^^^^^^^^^
  File "/opt/airflow/venv/lib64/python3.11/site-packages/airflow/operators/python.py", line 238, in execute
    return_value = self.execute_callable()
                   ^^^^^^^^^^^^^^^^^^^^^^^
  File "/opt/airflow/venv/lib64/python3.11/site-packages/airflow/operators/python.py", line 256, in execute_callable
    return runner.run(*self.op_args, **self.op_kwargs)
           ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
  File "/opt/airflow/venv/lib64/python3.11/site-packages/airflow/utils/operator_helpers.py", line 252, in run
    return self.func(*args, **kwargs)
           ^^^^^^^^^^^^^^^^^^^^^^^^^^
  File "/opt/news-datalake/dags/news_datalake_pipeline.py", line 172, in silver_publish
    raise AirflowFailException(f"{_tag(context)} {exc}")   # sin reintentos: fallo controlado
    ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
airflow.exceptions.AirflowFailException: [run_id=manual__2026-11-05T02:47:11+00:00 task=silver_publish] Fallo simulado en silver_publish antes del commit
[2026-11-05, 02:47:27 UTC] {taskinstance.py:1226} INFO - Immediate failure requested. Marking task as FAILED. dag_id=news_datalake_pipeline,
task_id=silver_publish, run_id=manual__2026-11-05T02:47:11+00:00, execution_date=20261105T024711, start_date=20261105T024726, end_date=20261105T024727
[2026-11-05, 02:47:27 UTC] {taskinstance.py:341} ▶ Post task execution logs
```

E49 · Ejecución registrada como FAILED



12_estado_ejecuciones | 13_resultados_valid... | 01_noticias_por_fec... | 02_noticias_por_dia... | 03_top10_organizac... | 04_top_personas_or... | 05_presencia_entida... | 06_frases_clave_por...

```
-- Estado de cada ejecución del DAG: COMPLETE, PARTIAL o FAILED, con el detalle por fuente.
SELECT finished_at_utc, run_id, mode, status, message, failed_tasks,
       transform(sources, s -> s.source_id || ':' || s.status) AS fuentes,
       news_current, silver_dirty_dates, quality_passed
FROM news_datalake.pipeline_run_log
ORDER BY finished_at_utc DESC
LIMIT 30;
```

SQL Ln 1, Col 1

Run again | Explain | Cancel | Clear | Create

Reuse query results up to 60 minutes ago

Query results | Query stats

Completed — Time in queue: 93 ms — Run time: 529 ms — Data scanned: 7.80 KB

Results (9)

Copy | Download results CSV

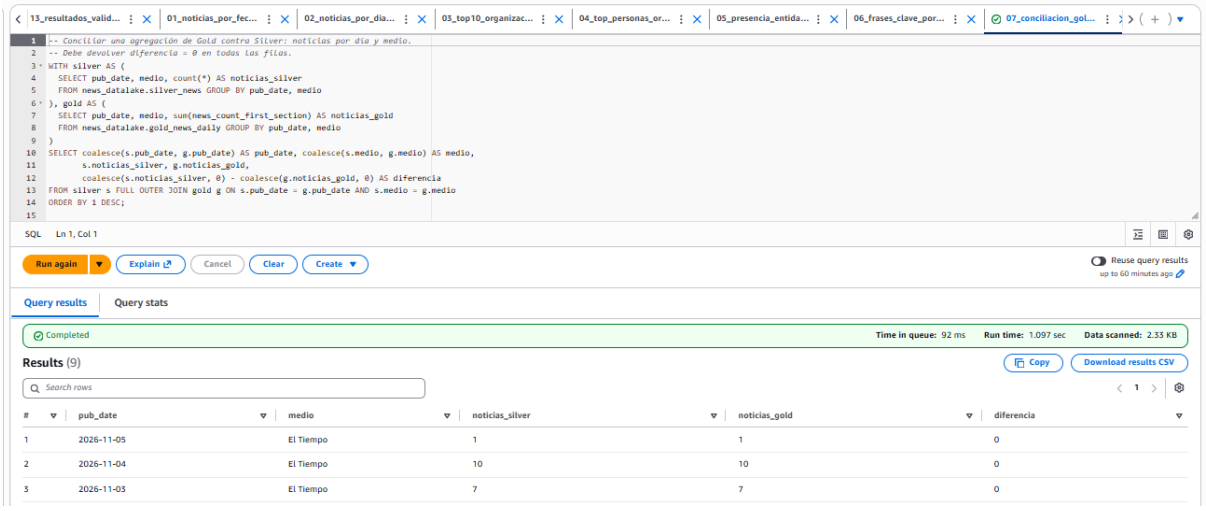
Search rows

#	finished_at_utc	run_id	mode	status	message	failed_tasks	fuentes
1	2026-11-05T02:47:30Z	manual__2026-11-05T02:47:11+00:00	extract	FAILED	Tareas fallidas: athena_validate, glue_update_catalog, gold_build, silver_publish	[athena_validate, glue_update_catalog, gold_build, silver_publish]	[eltiempo_medi
2	2026-11-05T02:42:52Z	manual__2026-11-05T02:41:58+00:00	reprocess	COMPLETE	Ejecución completa	[]	[]



	fuentes	news_current	silver_dirty_dates	quality_passed
build, silver_publish]	[eltiempo_medio_ambiente:SUCCESS, eltiempo_ciencia:SUCCESS, eltiempo_viajar:SUCCESS]		[]	false
	[]	30	[2026-11-04]	true
	[]	30	[2026-11-04]	true

E50 · Athena sin cambios tras el fallo



```
-- Conciliar una agregación de Gold contra Silver: noticias por día y medio.
-- Debe devolver diferencia = 0 en todas las filas.
WITH silver AS (
  SELECT pub_date, medio, count(*) AS noticias_silver
  FROM news_datalake.silver_news GROUP BY pub_date, medio
), gold AS (
  SELECT pub_date, medio, sum(news_count_first_section) AS noticias_gold
  FROM news_datalake.gold_news_daily GROUP BY pub_date, medio
)
SELECT coalesce(s.pub_date, g.pub_date) AS pub_date, coalesce(s.medio, g.medio) AS medio,
       s.noticias_silver, g.noticias_gold,
       coalesce(s.noticias_silver, 0) - coalesce(g.noticias_gold, 0) AS diferencia
FROM silver s FULL OUTER JOIN gold g ON s.pub_date = g.pub_date AND s.medio = g.medio
ORDER BY 1 DESC;
```

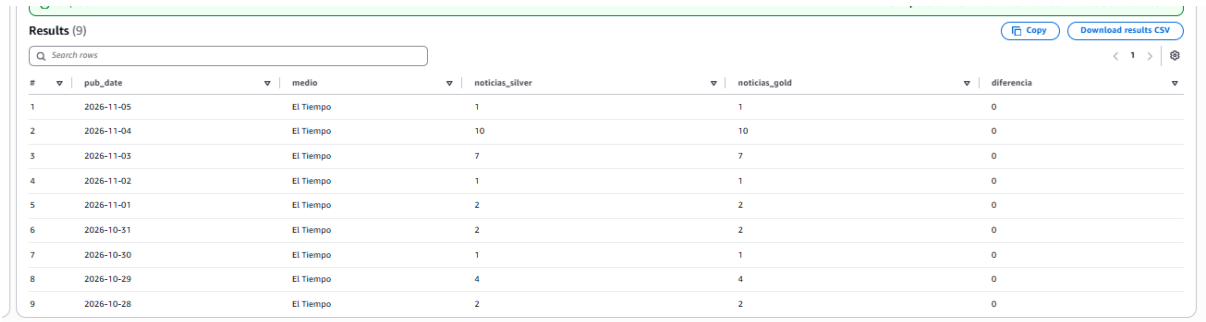
Run again · Explain · Cancel · Clear · Create · Reuse query results up to 60 minutes ago

Query results | Query stats

Completed — Time in queue: 92 ms · Run time: 1.097 sec · Data scanned: 2.33 KB

Results (9) — Copy · Download results CSV

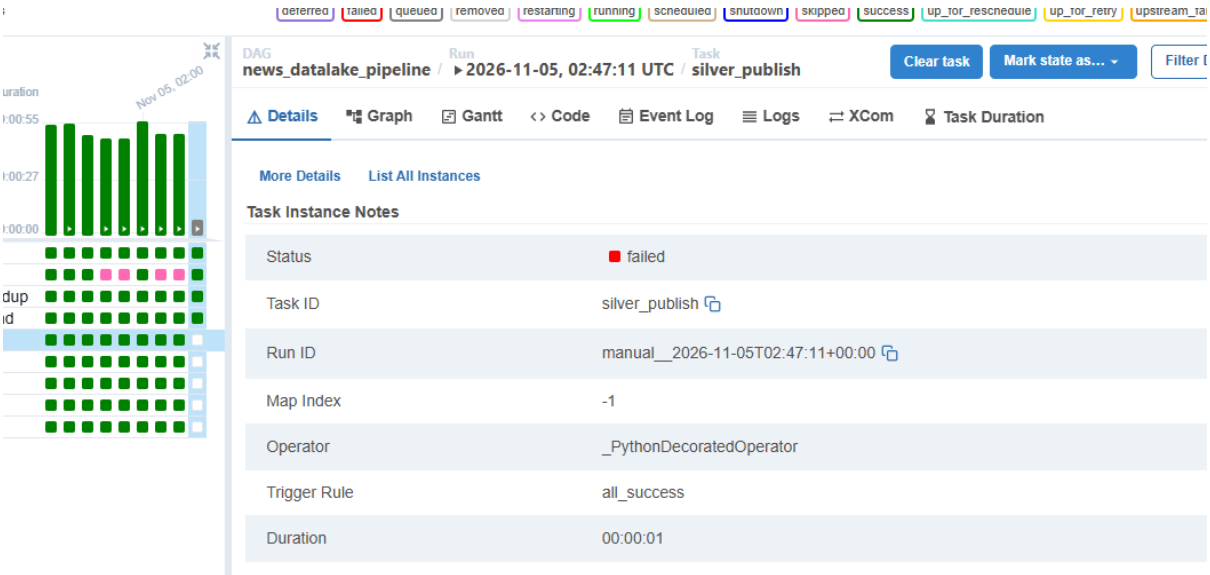
#	pub_date	medio	noticias_silver	noticias_gold	diferencia
1	2026-11-05	El Tiempo	1	1	0
2	2026-11-04	El Tiempo	10	10	0
3	2026-11-03	El Tiempo	7	7	0



Results (9) — Copy · Download results CSV

#	pub_date	medio	noticias_silver	noticias_gold	diferencia
1	2026-11-05	El Tiempo	1	1	0
2	2026-11-04	El Tiempo	10	10	0
3	2026-11-03	El Tiempo	7	7	0
4	2026-11-02	El Tiempo	1	1	0
5	2026-11-01	El Tiempo	2	2	0
6	2026-10-31	El Tiempo	2	2	0
7	2026-10-30	El Tiempo	1	1	0
8	2026-10-29	El Tiempo	4	4	0
9	2026-10-28	El Tiempo	2	2	0

E51 · Reejecución exitosa de la misma ejecución



deferred · failed · queued · removed · restarting · running · scheduled · shutdown · skipped · success · up_for_reschedule · up_for_retry · upstream_failed

DAG: news_datalake_pipeline / Run: ▸2026-11-05, 02:47:11 UTC / Task: silver_publish

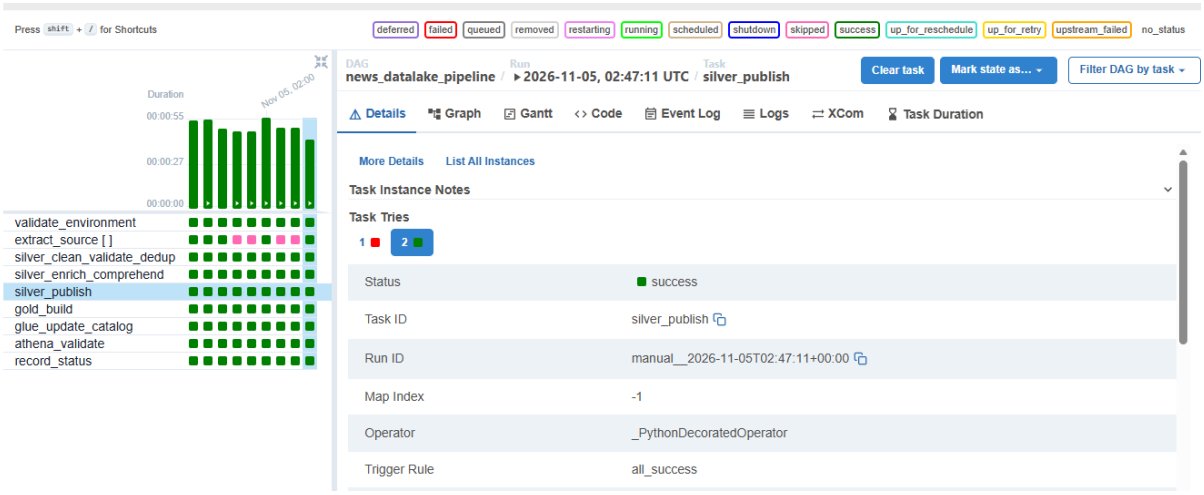
Clear task · Mark state as... · Filter

Details | Graph | Gantt | Code | Event Log | Logs | XCom | Task Duration

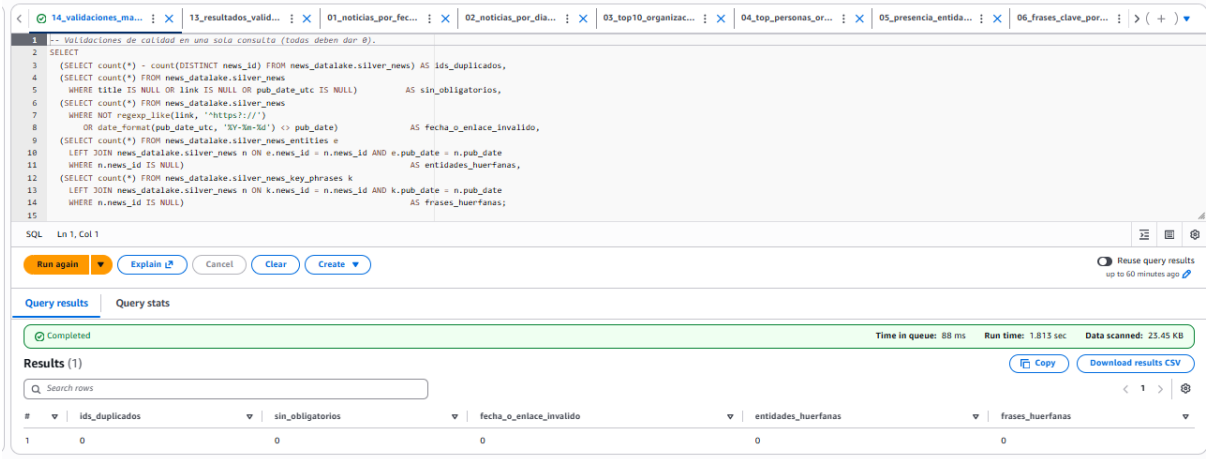
More Details · List All Instances

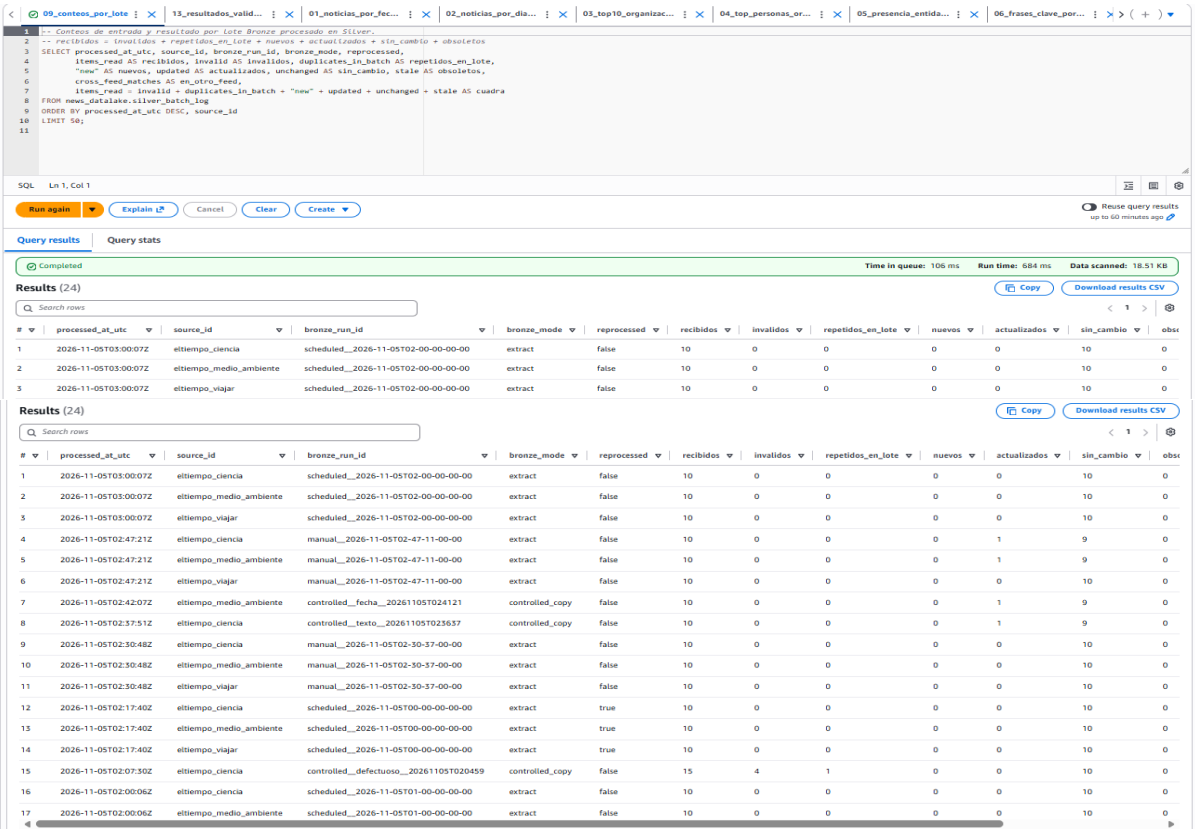
Task Instance Notes

Status	failed
Task ID	silver_publish
Run ID	manual__2026-11-05T02:47:11+00:00
Map Index	-1
Operator	_PythonDecoratedOperator
Trigger Rule	all_success
Duration	00:00:01



E52 · Sin duplicados después de recuperar

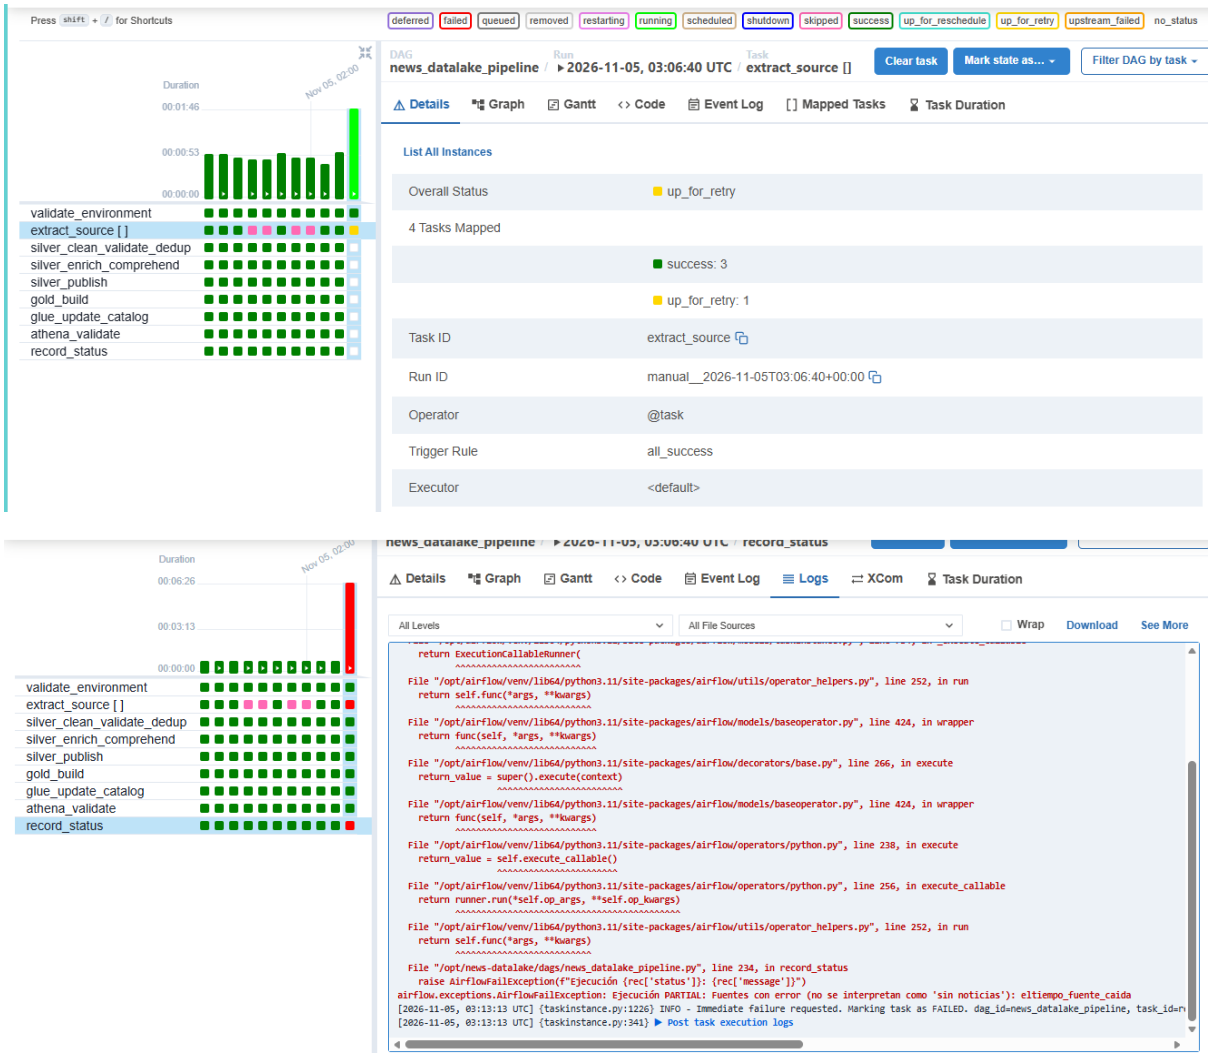




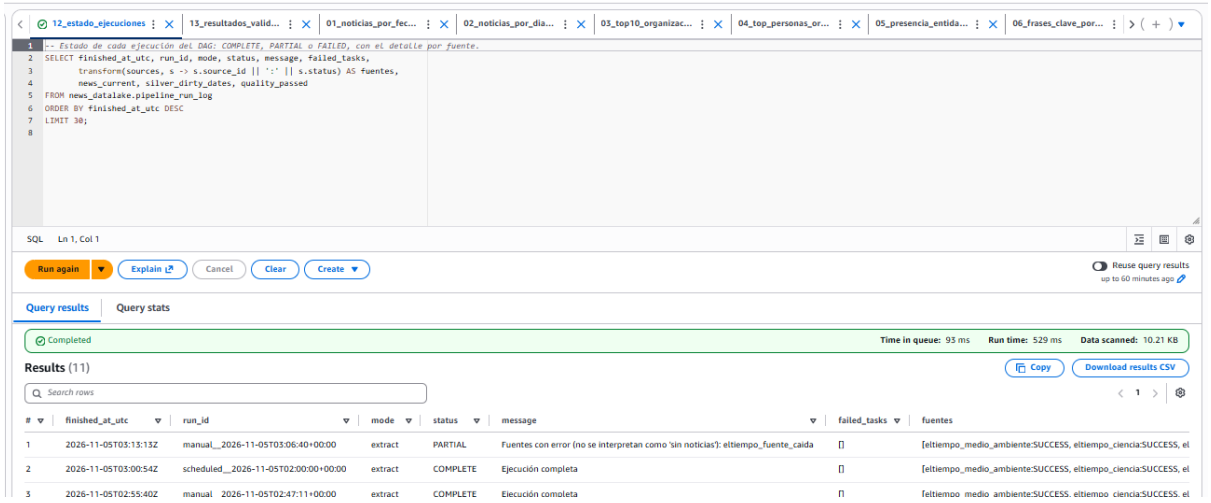
5.6 Fuente no disponible (ejecución parcial)

Resultado esperado: La fuente caída se identifica; la ejecución queda PARTIAL y no se interpreta como fuente sin noticias.

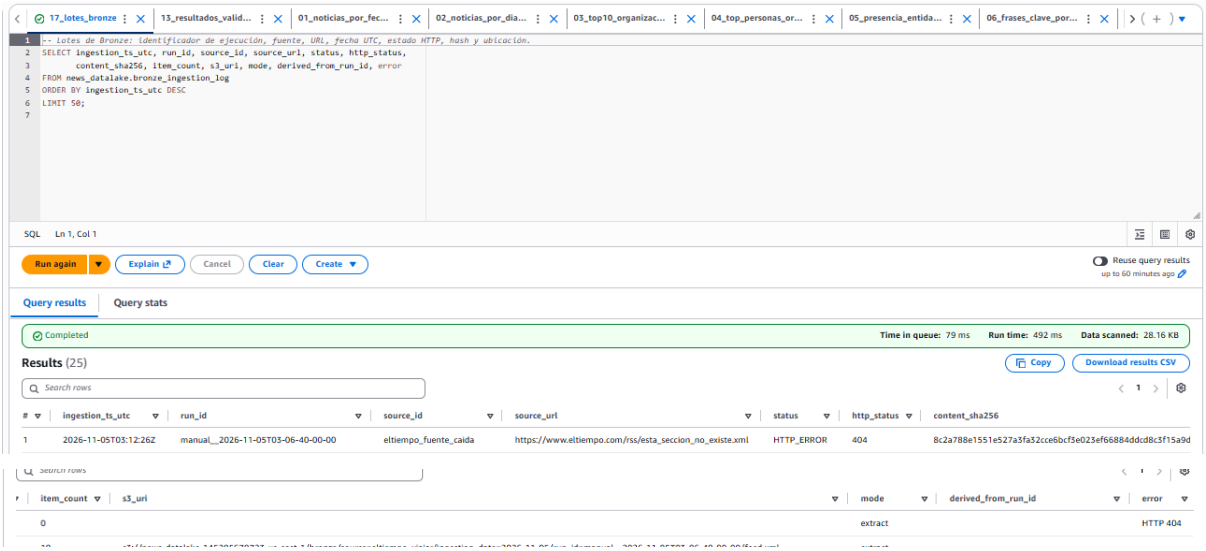
E53 · DAG con una fuente caída



E54 · Ejecución registrada como PARTIAL



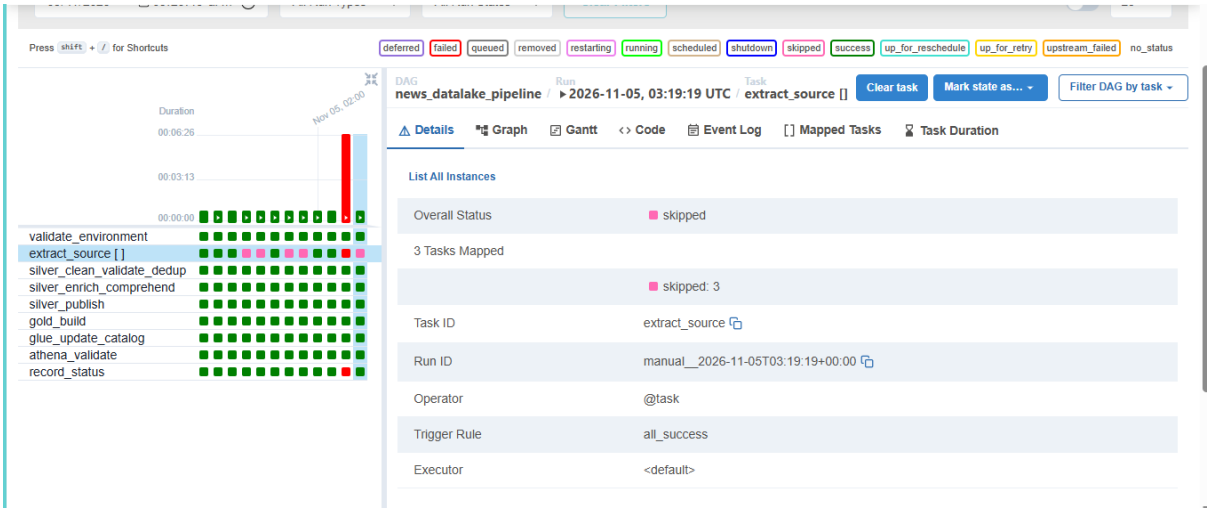
fuentes	news_current	silver_dirty_dates	qu
[eltiempo_medio_ambiente:SUCCESS, eltiempo_ciencia:SUCCESS, eltiempo_viajar:SUCCESS, eltiempo_fuente_caida:HTTP_ERROR]	30	[]	tru
[eltiempo_medio_ambiente:SUCCESS, eltiempo_ciencia:SUCCESS, eltiempo_viajar:SUCCESS]	30	[]	tru



5.7 Reprocesamiento desde Bronze

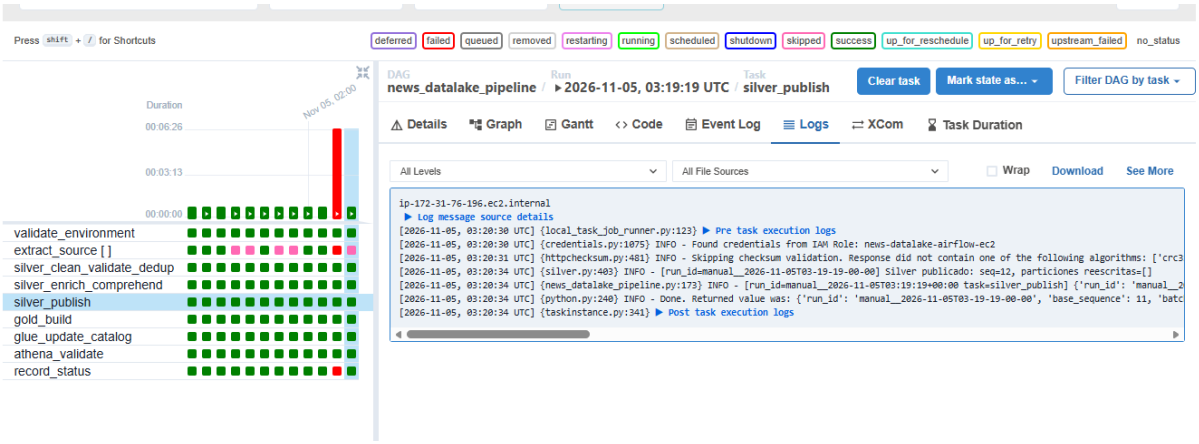
Resultado esperado: Reconstrucción de resultados sin volver a consultar los RSS.

E55 · Rebuild sin extracción de RSS

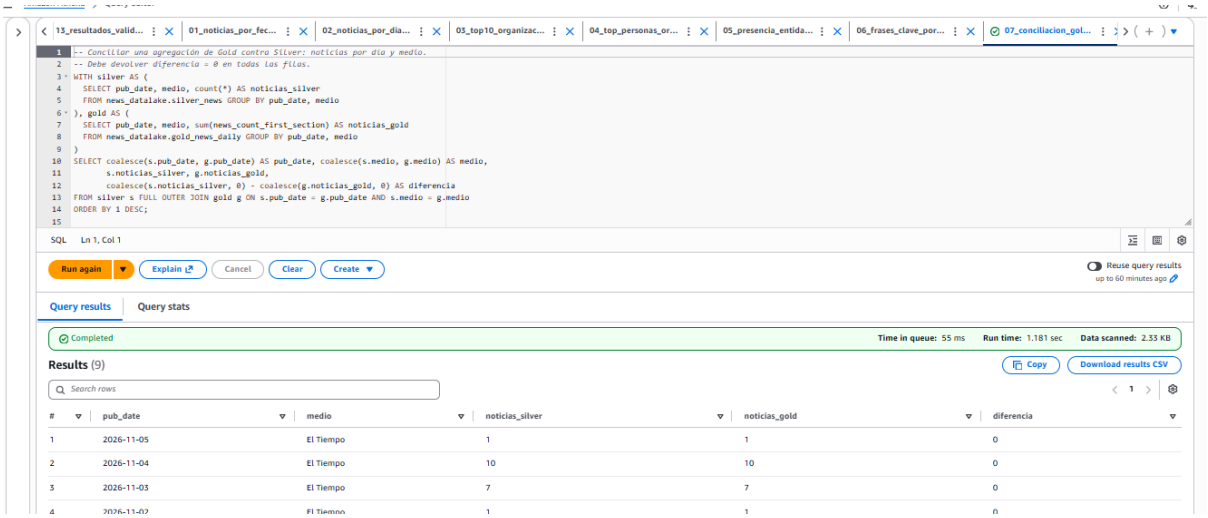


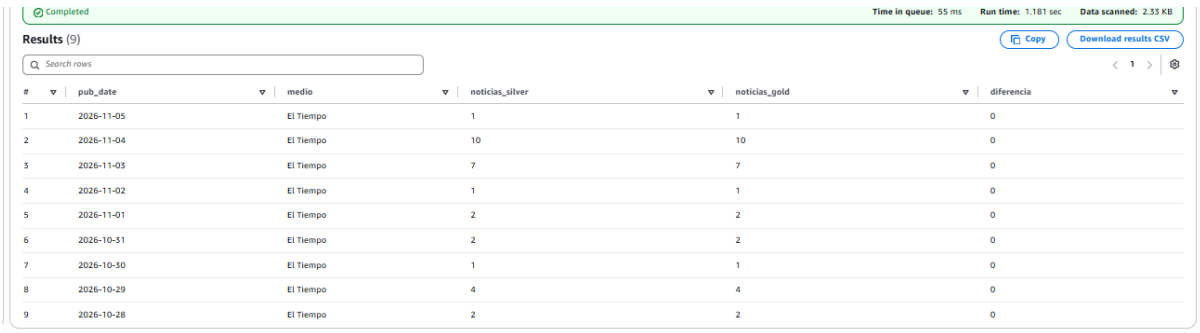
E56 · Logs del rebuild





E57 · Conciliación después del rebuild

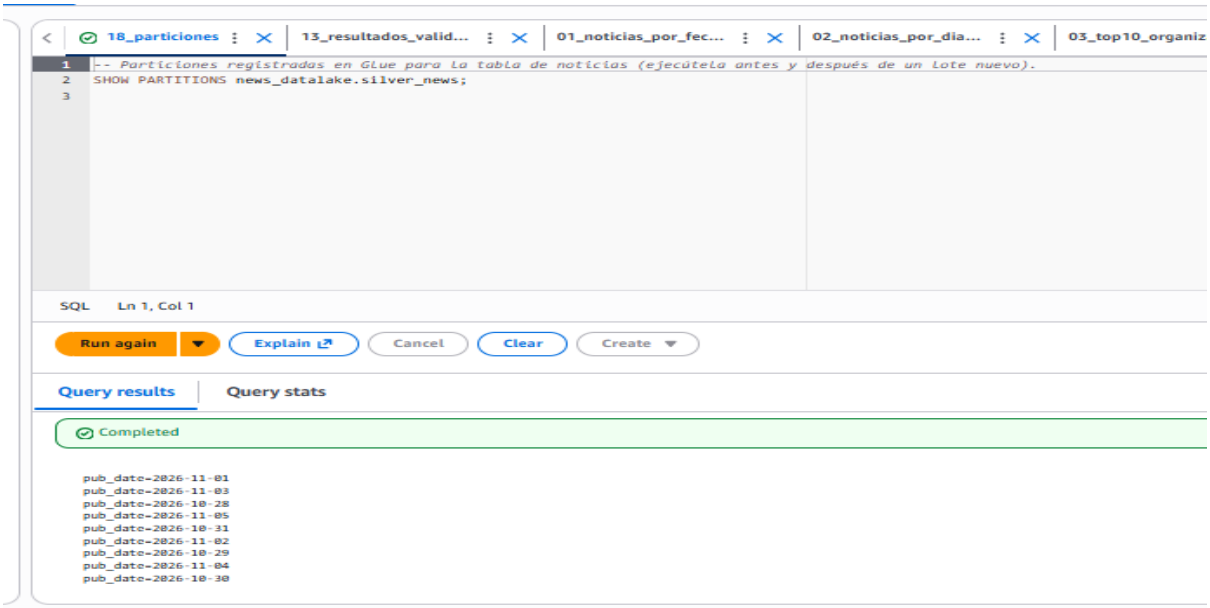




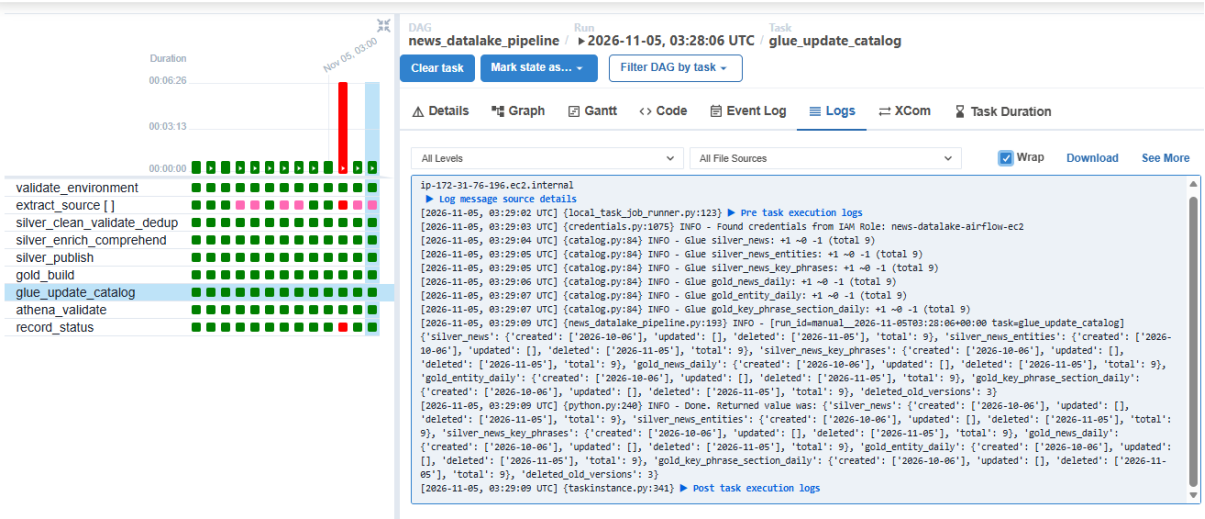
5.8 Nueva partición

Resultado esperado: Datos disponibles en Athena después de actualizar los metadatos correspondientes.

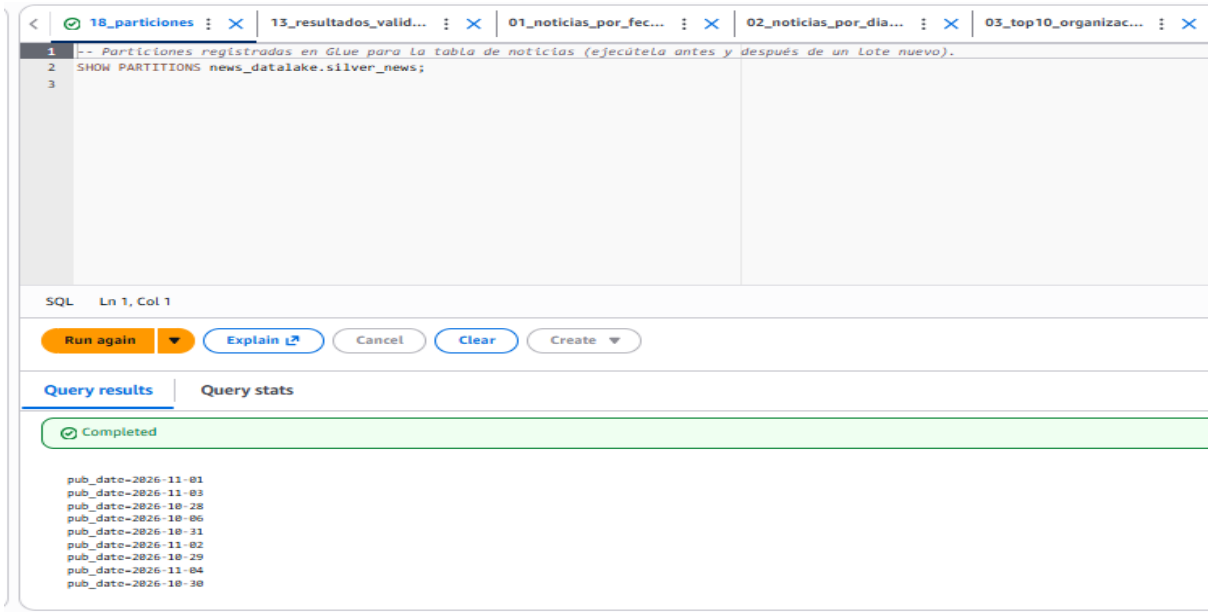
E58 · Particiones antes del lote nuevo



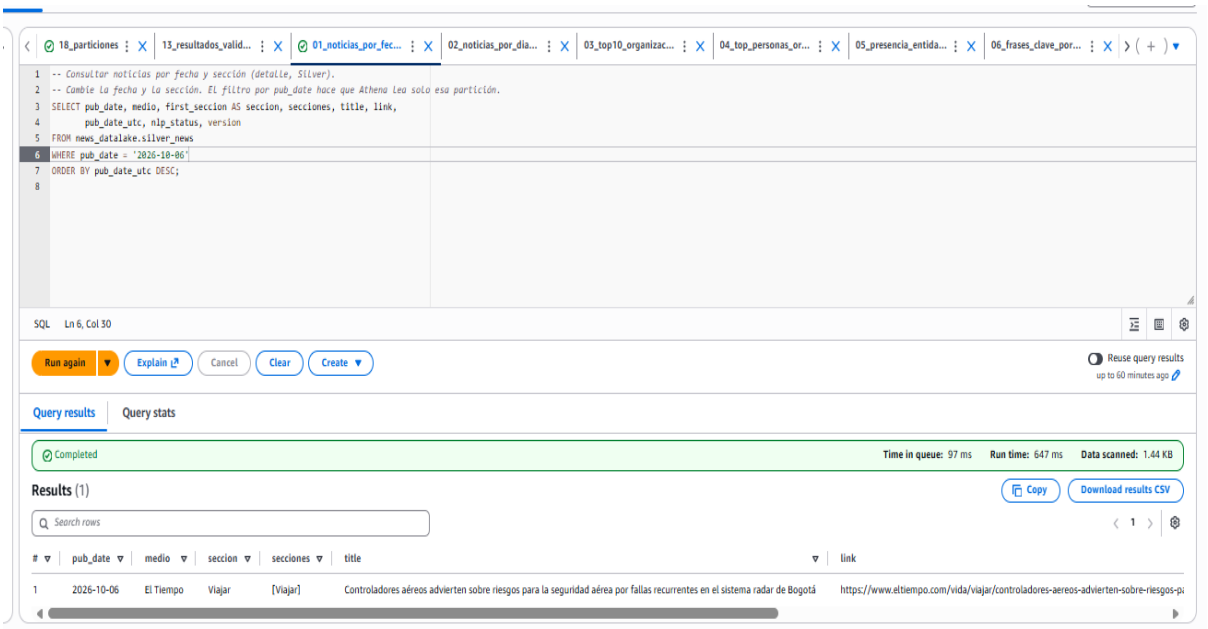
E59 · Log de Glue: partición creada



E60 · Particiones después del lote nuevo



E61 · Datos disponibles en la nueva partición

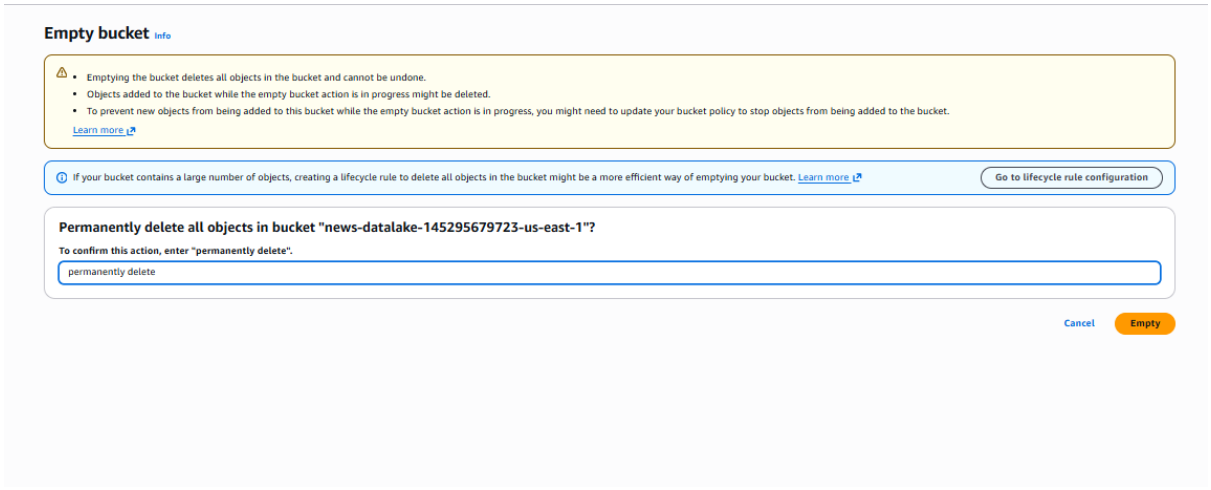


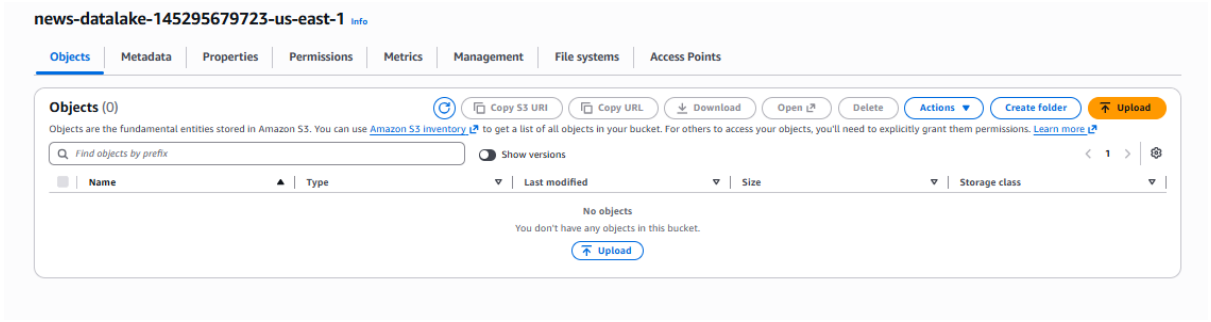
6. Eliminación de recursos

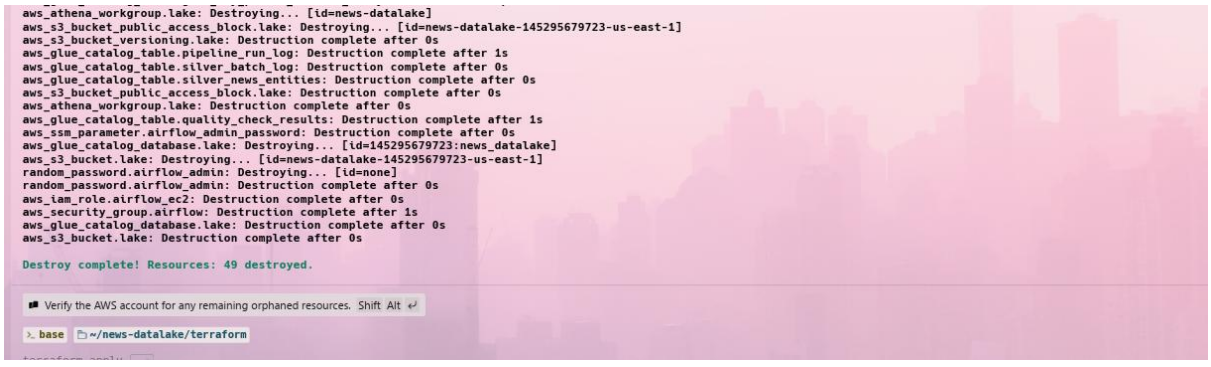
Eliminación de la infraestructura al terminar.

E62 · Eliminación de recursos









Limitación del enriquecimiento:

El análisis usa solo el título y el resumen del RSS, no el artículo completo. Con tan poco texto, Comprehend omite entidades que solo aparecen en el cuerpo de la nota y a veces clasifica mal menciones ambiguas o siglas. Por eso, los indicadores de Gold miden menciones detectadas automáticamente en títulos y resúmenes, no la presencia real de una entidad en la noticia. Además, no se resuelven alias: “Petro” y “Gustavo Petro” cuentan como entidades distintas.